

分类号: \_\_\_\_\_

密级: \_\_\_\_\_

U D C : \_\_\_\_\_

编号: 2021240523

# 雲南農業大學

## 全日制专业硕士学位论文

### 基于冠层多光谱图像的玉米地上部 生物量估算方法研究

Research on maize aerial biomass estimation method based  
on canopy multispectral image

硕 士 研 究 生: 黄晓东

指 导 教 师: 李文峰教授

申 请 学 位 类 别: 农业硕士

专 业: 农业工程与信息技术

培 养 学 院: 大数据学院

二 0 二 三 年 五 月

## 摘要

玉米 (Maize) 是我国种植面积第一的农作物, 其次是小麦和水稻。近几年, 随着玉米种植面积与产量的增加, 玉米长势如何越来越好的问题受到广泛关注, 而跟长势有关的地上部生物量的预测也成为焦点。地上部生物量 (AGB) 是一种用来反映作物表型和有效监测作物生长情况的参数, 它是描述植被生长状态的重要指标, 对于预测农作物生长趋势和产量具有重要意义。传统的测量AGB方法需要人工测量, 且采集困难。为了快速准确知道玉米的AGB以及长势, 基于冠层多光谱图像来预测AGB的形式是有必要的。这也是我国现阶段对于玉米研究的重点。

本研究以2022-2023年在云南省楚雄州双柏县爱尼山乡和云南省德宏州芒市勐戛镇试验地的田间玉米实验为基础, 利用大疆精灵4多光谱无人机 (P4M) 获取试验区玉米拔节期、吐丝期、灌浆期的遥感影像, 通过在每个小区随机获取五株玉米植株的方法获取地上部生物量实测值, 选取5种植被指数 (比值植被指数RVI、差值环境植被指数DVI、归一化差值植被指数NDVI、增强型植被指数EVI、优化土壤调节植被指数OSAVI), 通过偏最小二乘法、岭回归算法、BP神经网络三种模型, 对试验区玉米进行AGB的反演研究, 研究内容如下:

(1) 无人机在执行任务过程中, 拍摄的图片会受到各种因素的影响, 从而产生图像畸变的问题。为了解决这种问题, 进行了无人机飞行路线的参数设置。通过在田间设置15米、25米、35米的飞行高度, 对比分析最终明确了最佳的飞行参数为: 飞行高度15m, 航向重叠度为80%和旁向重叠度为70%时, 可以获取清晰度较高的遥感影像。

(2) 基于多光谱图像利用偏最小二乘算法实现生物量预测, 构建了观测拔节期、吐丝期、灌浆期, 三个阶段下的植被指数反射率与地上部生物量构建模型。在模型检验中, 利用偏最小二乘算法构建灌浆期的实测值-DVI预测值模型精度最高, 决定系数 $R^2$ 为0.917, 均方根误差RMSE为16.99g/m<sup>2</sup>, 归一化均方根误差NRMSE为28.31%。试验结果表明, 偏最小二乘法模型在灌浆期可以较准确的预测玉米地上部生物量。

(3) 基于多光谱图像利用岭回归算法实现生物量预测, 将EVI、OSAVI、DVI、NDVI和RVI五种植被指数融合作为模型的输入量, 地上部生物量为输出量, 进行岭回归模型的构建。在模型检验中, 利用岭回归算法构建的吐丝期的模型检验精度最高, 决定系数 $R^2$ 为0.89, 均方根误差RMSE为12.03g/m<sup>2</sup>, 归一化均方根误差NRMSE为14.73%。

试验结果表明,岭回归模型在吐丝期可以较准确的预测玉米地上部生物量。

(4) 基于多光谱图像利用BP神经网络算法实现生物预测,构建五种植被指数融合与地上部生物量的模型。在模型检验中,灌浆期的预测模型精度最高,决定系数 $R^2$ 为0.928,均方根误差RMSE为 $21.32\text{g}/\text{m}^2$ ,归一化均方根误差NRMSE为9.84%。BP神经网络对地上部生物量训练集预测的准确率为90.31%,召回率为86.47%。试验结果表明,BP神经网络在灌浆期可以较准确的预测玉米地上部生物量。

(5) 通过模型结果对比分析,得到BP神经网络在拔节期建模结果精度达到了89.5%,模型检验精度达到了84.9%;吐丝期建模结果精度达到了86.6%,模型检验精度达到了91.4%;灌浆期建模结果精度达到了85.5%,模型检验精度达到了92.6%,较其他模型精度均有提高。结合以上分析,确定了BP神经网络是最佳的反演模型,并对三个时期的玉米遥感影像进行了AGB反演,得到地上部生物量空间分布图。

研究表明,无人机多光谱影像可以很好的进行玉米地上部生物量的估算,并利用估算得到的地上部生物量反演空间分布图,预测地上部生物量可以帮助农民估产,有力地推动了我国农作物遥感理论的研究与应用。

**关键词:** 地上部生物量; 无人机遥感; 偏最小二乘法; 岭回归算法; BP神经网络

# Research on maize aerial biomass estimation method based on canopy multispectral image

XiaoDong Huang

Directed by Wenfeng Li

## Abstract

Maize (Maize) is the largest crop planted in our country, followed by wheat and rice. In recent years, with the increase of corn planting area and yield, the growth of corn has been paid more and more attention, and the prediction of aboveground biomass related to growth has also become the focus. Aboveground biomass (AGB) is a parameter used to reflect crop phenotype and effectively monitor crop growth. It is an important indicator to describe vegetation growth state and has great significance for predicting crop growth trend and yield. The traditional AGB measurement method requires manual measurement and is difficult to collect. In order to quickly and accurately know the AGB and growth trend of maize, it is necessary to predict the form of AGB based on canopy multispectral images. This is our current focus of corn research.

Based on field maize experiments in Ainishan Township, Shuangbai County, Chuxiong Prefecture, Yunnan Province, and Mengjie Town, Mengjie Town, Manshi City, Dehong Prefecture, Yunnan Province during 2022-2023, this study used DJI Sprin-4 multispectral UAV (P4M) to obtain remote sensing images of maize at the joint, silking and grouting stages in the experimental areas. The measured aboveground biomass was obtained by randomly obtaining five maize plants in each plot, and five vegetation indices were selected (ratio vegetation index RVI, difference environmental vegetation index DVI, normalized difference vegetation index NDVI, enhanced vegetation index EVI, and optimized soil-regulated vegetation index OSAVI). Partial least square method, ridge regression algorithm and BP neural network were used to invert AGB of maize in the test area. The research contents were as follows:

(1) During the execution of tasks, the pictures taken by UAV will be affected by various factors, resulting in the problem of image distortion. In order to solve this problem, the parameters of UAV flight path are set. By setting flight altitudes of 15 meters, 25 meters and 35 meters in the field, the optimal flight parameters were determined as follows: flight height of 15 meters, course overlap of 80% and side overlap of 70%, the remote

sensing image with higher definition could be obtained.

(2) Based on the multi-spectral images, partial least squares algorithm was used to predict the biomass, and the vegetation index reflectance and aboveground biomass construction models were constructed under the observation of jointing stage, spinneret stage and grout stage. Among the prediction results, partial least square algorithm was used to construct the measured value-DVI predicted value model at grout stage with the highest accuracy, the coefficient of determination  $R^2$  was 0.917, the root mean square error RMSE was  $16.99\text{g/m}^2$ , and the normalized root mean square error NRMSE was 28.31%. The experimental results showed that the partial least squares model could accurately predict the biomass of the upper part of the corn field in the filling stage.

(3) The ridge regression algorithm was used to predict the biomass based on multi-spectral images. The ridge regression model was constructed by exponential fusion of EVI, OSAVI, DVI, NDVI and RVI as the input of the model and the aboveground biomass as the output. Among the prediction results, Ridge regression algorithm was used to construct the prediction result model of spinneret stage with the highest accuracy, the coefficient of determination  $R^2$  was 0.89, the root mean square error RMSE was  $12.03\text{g/m}^2$ , and the normalized root mean square error NRMSE was 14.73%. The experimental results showed that the ridge regression model could accurately predict the biomass of the upper part of corn field in the silking stage.

(4) Based on multi-spectral images, BP neural network algorithm was used to achieve biological prediction, and a model of exponential fusion of five planting covers and aboveground biomass was constructed. Among the prediction results, the prediction model of grouting stage has the highest accuracy, the determination coefficient  $R^2$  is 0.928, the root-mean-square error RMSE is  $21.32\text{g/m}^2$ , and the normalized root-mean-square error NRMSE is 9.84%. The accuracy and recall rate of aboveground biomass training set were 90.31% and 86.47% respectively. The experimental results showed that BP neural network could accurately predict the biomass of the upper part of corn field in the filling stage.

(5) Through comparative analysis of model results, the accuracy of modeling results and prediction results reached 89.5% and 84.9% in jointing stage. The accuracy of the modeling results and the prediction results reached 86.6% and 91.4% respectively. The accuracy of modeling results in grouting stage reached 85.5%, and the accuracy of forecasting results in grouting stage reached 92.6%, which was higher than other models. The BP neural network was determined to be the best inversion model, and AGB inversion

was carried out on the remote sensing images of maize in three periods to obtain the spatial distribution map of aboveground biomass.

The results show that the UAV multi-spectral image can well estimate the biomass of the upper part of the corn field, and using the estimated aboveground biomass inversion spatial distribution map, predicting aboveground biomass can help farmers estimate their yield, and effectively promote the research and application of remote sensing theory of crops in China.

**KeyWords:** aboveground biomass; UAV remote sensing; partial least squares; ridge regression algorithm; BP neural networks

# 目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	3
1.2.1 无人机遥感技术现状.....	3
1.2.2 玉米地上部生物量估算研究现状.....	4
1.3 研究内容和技术路线.....	5
1.3.1 研究内容.....	5
1.3.2 技术路线.....	6
1.4 全文的组织结构.....	7
第 2 章 试验设计与理论基础 .....	9
2.1 试验区概况.....	9
2.2 试验设计.....	10
2.2.1 玉米鲜重测定.....	10
2.2.2 玉米干重测定.....	11
2.3 数据获取与预处理.....	12
2.3.1 数据采集平台.....	12
2.3.2 多光谱数据获取.....	13
2.3.3 多光谱数据预处理.....	15
2.4 植被指数的选择与提取.....	16
2.5 相关方法理论基础.....	18
2.5.1 偏最小二乘法.....	18
2.5.2 岭回归算法.....	19
2.5.3 BP 神经网络.....	20
2.6 模型精确度的检验.....	22
2.7 本章小结.....	24
第 3 章 基于偏最小二乘法模型的地上部生物量反演模型研究 .....	25
3.1 基于偏最小二乘法模型的参数优化 .....	25
3.2 基于偏最小二乘法模型的建模分析 .....	25
3.2.1 玉米拔节期地上部生物量建模分析.....	26
3.2.2 玉米吐丝期地上部生物量建模分析.....	27
3.2.3 玉米灌浆期地上部生物量建模分析.....	28
3.3 基于偏最小二乘法模型的模型检验 .....	29
3.3.1 玉米拔节期地上部生物量模型检验.....	30
3.3.2 玉米吐丝期地上部生物量模型检验.....	31

3.3.3 玉米灌浆期地上部生物量模型检验.....	32
3.4 本章小结.....	34
第4章 基于岭回归算法的地上部生物量反演模型研究 .....	35
4.1 基于岭回归模型的参数的优化 .....	35
4.2 基于岭回归模型的建模分析 .....	36
4.2.1 玉米拔节期地上部生物量建模分析.....	36
4.2.2 玉米吐丝期地上部生物量建模分析.....	37
4.2.3 玉米灌浆期地上部生物量建模分析.....	37
4.3 基于岭回归模型的模型检验 .....	38
4.3.1 玉米拔节期地上部生物量模型检验.....	38
4.3.2 玉米吐丝期地上部生物量模型检验.....	38
4.3.3 玉米灌浆期地上部生物量模型检验.....	39
4.4 本章小结.....	40
第5章 基于BP神经网络算法的地上部生物量反演模型研究 .....	41
5.1 基于BP神经网络模型参数优化与训练 .....	41
5.1.1 模型参数优化.....	41
5.1.2 模型训练.....	41
5.2 基于BP神经网络模型的建模分析.....	42
5.2.1 玉米拔节期地上部生物量建模分析.....	42
5.2.2 玉米吐丝期地上部生物量建模分析.....	43
5.2.3 玉米灌浆期地上部生物量建模分析.....	43
5.3 基于BP神经网络模型的模型检验.....	44
5.3.1 玉米拔节期地上部生物量模型检验.....	44
5.3.2 玉米吐丝期地上部生物量模型检验.....	45
5.3.3 玉米灌浆期地上部生物量模型检验.....	45
5.4 本章小结.....	46
第6章 各模型结果对比分析 .....	47
6.1 各模型的模型检验对比.....	47
6.2 各模型精度对比分析.....	48
6.2.1 建模结果精度分析 .....	48
6.2.2 模型检验精度分析 .....	49
6.3 地上部生物量反演结果.....	51
6.4 本章小结.....	51
第7章 总结与展望 .....	52
7.1 总结.....	52
7.2 展望.....	53
参考文献.....	54



## 第1章 绪论

### 1.1 研究背景和意义

玉米作为我国旱地农作物的代表之一，在所有农作物中播种面积位列第一<sup>[1]</sup>。玉米作为我国主要粮食作物，在单位面积内可以快速提高产量<sup>[2]</sup>。现今，玉米不仅可以作为粮食，还可以用作加工原料、饲料以及能源等多个方面，其地位对于全球粮食安全和国民经济保障具有重要意义<sup>[3]</sup>。由于中国拥有广阔的土地和众多的人口，再加上玉米生长对水资源需求较低，因此在许多地区都可以进行玉米种植<sup>[4]</sup>。根据2022年农业部种植业司的数据统计，中国玉米的种植总面积达到4307万公顷，玉米生产总量高达27255万吨，种植面积和生产总量在全球都位居第一。玉米的生育期里有几个极为重要，分别是拔节期、吐丝期、灌浆期。它们属于玉米物候期的三个重要时期，这些时期吸收营养和积累物质的速度是最快的<sup>[5]</sup>。而准确知道玉米的长势以及进行相应的优培是很有意义的，具备研究价值<sup>[6]</sup>。同样的，种植密度也可以影响产量的增加，合理的种植密度能够增加产量，增加地上部生物量，提高长势<sup>[7]</sup>。

地上部生物量（Above-Ground-Biomass, AGB）是作物活力和净初级生产力的基础，能够对作物的长势状况和光合作用强度进行相应体现的重要农艺参数<sup>[8]</sup>。为了测量AGB，传统做法是采用随机取样法，但同时也会破坏玉米大田。获取AGB信息的速度越快且没有任何损伤，对于指导农业生产管理和精准施肥至关重要<sup>[9]</sup>。

随着遥感平台的多样性和影像空间分辨率的不断提高，遥感技术被广泛认为是监测和估算大面积作物地上部生物量（AGB）最为有效的技术手段<sup>[10]</sup>。其中，低空无人机遥感平台具备机动灵活性，能够提供更高的时间、空间和光谱分辨率的遥感数据，具有许多优势，从而成为了精准农业中定量观测使用最为频繁的技术工具<sup>[11]</sup>。

目前，无人机平台上主要使用的传感器有三种，分别是数码传感器、多光谱传感器和高光谱传感器。数码相机搭载的传感器价格较低，但其波段数量相对较少，这可能导致在解析作物冠层光谱信息时存在较大的困难。高光谱传感器的优点主要体现在其能够快速处理作物冠层的光谱信息，从而提供更为详细和精确的数据。然而，高光谱传感器的价格通常较其他传感器昂贵几倍，同时其数据处理也可能较为困难。这可能对使用高光谱传感器进行作物监测和研究的成本和技术要求带来一定的挑战。如今检测光谱信息，大多数要用到多光谱传感器来进行检测，不仅价格低

廉还包含有监测农学参数信息重要的红边波段，所以在大田遥感监测方面收到很多人的追捧<sup>[12]</sup>。作物生长的整个物候期中，受到的影响因素有很多，如作物冠层结构、叶片形态以及生理生态特征的变化，导致了作物冠层在图像中体现出的光谱特征存在差异。为了增强植被信息，可以将两个或多个波段的反射率通过线性或非线性的组合运算来实现，从而降低环境和背景因素对植被光谱特征的干扰<sup>[13]</sup>。常见的差值植被指数DVI、优化土壤调节植被指数OSAVI以及增强型植被指数EVI等都是对于生物量检测表现良好的几种植被指数<sup>[14]</sup>。

在21世纪初期，由于当时的条件限制，许多学者在进行作物研究时只能依赖卫星遥感数据，但由于其分辨率较低，得到的数据精度有限。然而，随着低空无人机技术的发展，具备高分辨率遥感能力的无人机应运而生。低空无人机具有快速、精确地监测作物农情信息的优势，从而为作物研究提供了更为高精度的数据来源。这一技术的出现为农业监测和作物研究提供了新的机会和可能性<sup>[15]</sup>。

本文在对云南省楚雄州双柏县爱尼山乡和云南省德宏州芒市勐戛镇的大田玉米地上部生物量进行监测研究时，基于其农情信息提取优势突出，采用了低空无人机这一技术。随着无人机技术的快速发展，其在获取地上部生物量、监测大田作物的农情信息、预测作物产量等方面发挥着重要作用<sup>[16]</sup>。通过无人机遥感技术，可以实现对作物生长过程的高精度监测，将农业生产过程向信息化、时效化、自动化方向推进，为我国农业发展提供了有力的支持<sup>[17]</sup>。这一领域的研究在农业科技创新和农业现代化推进中具有重要地位，并为农田管理、作物精准管理、农业资源优化配置等提供了科学依据和技术支持。无人机因为小巧而机动灵活且易于携带的优势，成为其广受欢迎的原因之一。在重大事件中，无人机通过设置飞行航线，在获取遥感信息的同时，可以快速分析事件具体情况，给出相应措施<sup>[18-20]</sup>。在多种复杂场景中，无人机都可以搭载不同的传感器，如多光谱、热红外和高光谱，对现场情况进行航拍获取遥感信息<sup>[21]</sup>。我国地形复杂，需要低空无人机这种能够解决卫星遥感工作成本高、干扰严重等问题的存在，其具有很高的运用价值<sup>[22]</sup>。因此，利用无人机多光谱遥感技术对实验区的大田玉米地上部生物量进行监测研究具有极其重要的意义，可以在一定程度上实现有效监测，从而更好地了解作物生长状况，为粮食生产提供数据支持<sup>[23]</sup>。

## 1.2 国内外研究现状

### 1.2.1 无人机遥感技术现状

无人驾驶飞机，又称为无人机（Unmanned Aerial Vehicle, UAV），它的功能主要通过无线电遥控设备来控制，是可以实现航线规划的飞行器。目前，用途广泛，可以结合遥感技术进行农情信息的检测，也可以搭载RGB可见光相机，进行摄影以及航拍。还可以根据采集的影像，通过人工智能技术，实现信息的加工处理<sup>[24]</sup>。目前，无人机可分为多旋翼无人机、固定翼无人机、无人飞艇、扑翼无人机等。而多旋翼无人机中，有一种可以应用在农情检测上，可以进行监测数据、喷药等等，那就是农用无人机<sup>[25]</sup>。

农用无人机上运用多光谱成像摄像机传感器可以帮助农民更加有效地管理作物、土壤、施肥和灌溉。尽可能地减少喷洒、化肥和浪费水分，同时提高农作物的产量，对农民和更多种情况都具有巨大的好处。多光谱相机遥感成像技术利用蓝色、绿色、红色、红边和近红外波段获取作物和植被的可见和不可见图像。多光谱图像集成到那些能将信息输出成有意义数据的软件中，这种土壤情况监测和作物数据使农民能够更有效地节省时间和金钱，同时减少农药的使用<sup>[26]</sup>。在2010年，鲁恒等<sup>[27]</sup>人通过研究无人机遥感技术在地震灾区重建中的应用以及三维可视化技术，避免了二维图像在复杂情况下可能带来的思维局限和片面性，以满足汶川地震灾区重建规划设计的需求。在2021年，尹逊堂等<sup>[28]</sup>人通过植保无人机研究了小麦病虫害防治技术，并结合现有信息技术，构造了科学的小麦病虫害防治技术。2016年，赵庆展等<sup>[29]</sup>人则利用固定翼无人机采集光谱信息，实现了玛纳斯河畔作物的分类，并得到了最佳的波段组合。在2012年，李冰等<sup>[30]</sup>人通过无人机研究了小麦不同生长时期覆盖度的时序变化曲线，并成功获得植被指数直方图和阈值。而在2015年，汪小钦等<sup>[31]</sup>人则基于无人机获取的RGB遥感数据，成功发明了一种原理类似归一化植被指数（NDVI）的可见光植被指数（VDVI），并成功分离植被信息。在2016年，张正健等<sup>[32]</sup>人通过无人机拍摄的RGB影像，分析了草地植被地上部生物量与植被指数之间的相关性，且效果良好。在2022年，宋成阳等<sup>[33]</sup>人则基于机器学习的方法，研究了灌浆期冬小麦冠层信息对小麦籽粒产量的估测潜力，并选取了13个多光谱植被指数与小区产量决定系数为0.4-0.84之间，田间实测值与遥感预测值高度一致。

### 1.2.2 玉米地上部生物量估算研究现状

许多学者在国内外利用无人机多光谱遥感技术进行作物的物理和化学参数监测的研究非常丰富。在这些研究中,光谱植被指数法已成为一种快速获取地表信息的有效手段。2018年,肖武等<sup>[34]</sup>人通过结合22种不同的植被指数,成功地运用BP神经网络技术,对采煤沉陷区上方的玉米作物地上部生物量进行了估算,并得出结果表明该模型的 $R^2$ 和RMSE分别为0.78和177.23g/m<sup>2</sup>,证明了该模型具有相对较高的准确性。2023年,于翔等<sup>[35]</sup>人根据多光谱信息建立了植被指数-AGB模型,与不同生育期数据对比,有较好的准确率和稳定性。该模型基于偏最小二乘回归(PLSR)方法构建,计算精准度相对较高。2022年,程冀文等<sup>[36]</sup>人,以库布其沙漠的沙柳为研究对象,采用基于BP神经网络的方法建立了沙柳生物量模型。研究旨在探究不同因子对沙柳生物量估算模型的影响,以期找到最优的沙柳生物量估算模型形式。结果表明, $R^2=0.97$ , RMSE=0.67, MAE=0.50,具有较高的准确度,模型性能良好。在2019年,邓江等<sup>[37]</sup>人利用搭载新型成像光谱仪的无人机,获取了作物的多光谱图像,并进行了棉花地上部生物量的估测研究。研究结果显示,基于植被指数的模型比基于光谱反射率的模型具有更好的估算效果,显著提高了估算精度。2017年,邹楠等<sup>[38]</sup>人研究表明,在种植密度为6万、12万和18万株·hm<sup>-2</sup>的条件下,春季玉米的RVI、NDVI和DVI与地上部生物量呈现出最佳的相关性,决定系数分别为0.762、0.691和0.648,这可以用于监测春季玉米在地上的生物量。2013年,庄东英等<sup>[39]</sup>人通过研究发现,比值植被指数对冬小麦生物量的估算具有明显优势。

在国外,2022年,Meiyan Shu等<sup>[40]</sup>人为评估不同生育期玉米AGB的估算精度,运用了6种植被指数以及相应的回归技术。在2019年,Lu Ning等<sup>[41]</sup>人利用无人机获取的RGB图像和点云数据,对不同品种、氮肥水平和播种密度的小麦进行了生物量估算,取得了最佳准确度, $R^2$ 值为0.78。在2017年,Meng meng等<sup>[42]</sup>人在获取彩色图像后,结合逐步回归模型进行了小麦生长状态的检测,模型检验的 $R^2$ 值为0.94, RMSE为0.02, NRMSE为0.06。另外,在2019年,Jiang等<sup>[43]</sup>人利用光谱图像生成的植被指数图结合RGB图像的Tin结构指数以及气象数据模拟,应用随机森林技术,得出决定系数高达0.92,表现出极高的精度。

在2019年,Rueda-Ayala等<sup>[44]</sup>人利用无人机技术结合RGB-D重建方法,成功实现了草地植物高度和生物量的监测。研究结果表明,基于RGB-D的高度和生物量估算均

呈现较大的相关性 ( $R^2 > 0.8$ )。此外,许多研究也利用遥感数据来估算不同类型植被的生物量,例如玉米、森林、作物和湿地等<sup>[45]</sup>。随着无人机飞行控制系统的成熟和成本的逐渐降低,越来越多的研究团队开始尝试利用搭载RGB相机和多光谱相机的无人机实现地上部生物量的估算<sup>[46]</sup>。

### 1.3 研究内容和技术路线

#### 1.3.1 研究内容

本文以云南省楚雄州双柏县爱尼山乡和云南省德宏州芒市勐戛镇试验地的玉米为研究对象,利用搭载在大疆精灵4无人机上的五波段多光谱相机,对试验区进行多光谱影像获取。同时采用划感兴趣区域的方法实测地面玉米的地上部生物量,研究围绕不同生育阶段的玉米植株进行了植被指数和地上部生物量的反演工作。主要研究内容如下:

##### (1) 基于无人机遥感系统的飞行参数设计

为了获取效果最佳的多光谱遥感影像,不同试验场地和田块高度可能会对影像质量产生影响。因此,需要通过多次试验来确定最佳的飞行参数。这样可以避免遥感影像产生不同程度的畸变,确保影像的准确性和可靠性。通过不断优化飞行参数,可以获得高质量的多光谱遥感影像,从而为作物的物理和化学参数监测研究提供可靠的数据基础。

##### (2) 玉米地上部生物量偏最小二乘法回归模型的构建与验证

利用偏最小二乘法模型,建立不同生育期的植被指数与AGB的模型,使用5种植被指数作为输入变量,实测的地上部生物量(AGB)作为输出变量,建立偏最小二乘法(PLSR)模型,并验证其精度。

##### (3) 玉米地上部生物量岭回归模型的构建与验证

利用岭回归的方法,将分别建立在不同生育期的植被指数与AGB之间的回归模型,并使用均方根误差、决定系数等指标进行精确度评价,以此来确定最优的反演模型。

##### (4) 玉米地上部生物量BP神经网络模型的构建与验证

利用BP神经网络模型,建立不同生育期的植被指数与AGB的模型,采用5个植被指数融合作为输入变量,以地面实测的AGB作为输出变量,建立支持BP神经网络模型,并验证其精度。

### 1.3.2 技术路线

本文使用大疆精灵4无人机搭载五波段多光谱相机对试验区进行多光谱影像获取，以监测地上部生物量。具体技术路线如图 1-1 所示。

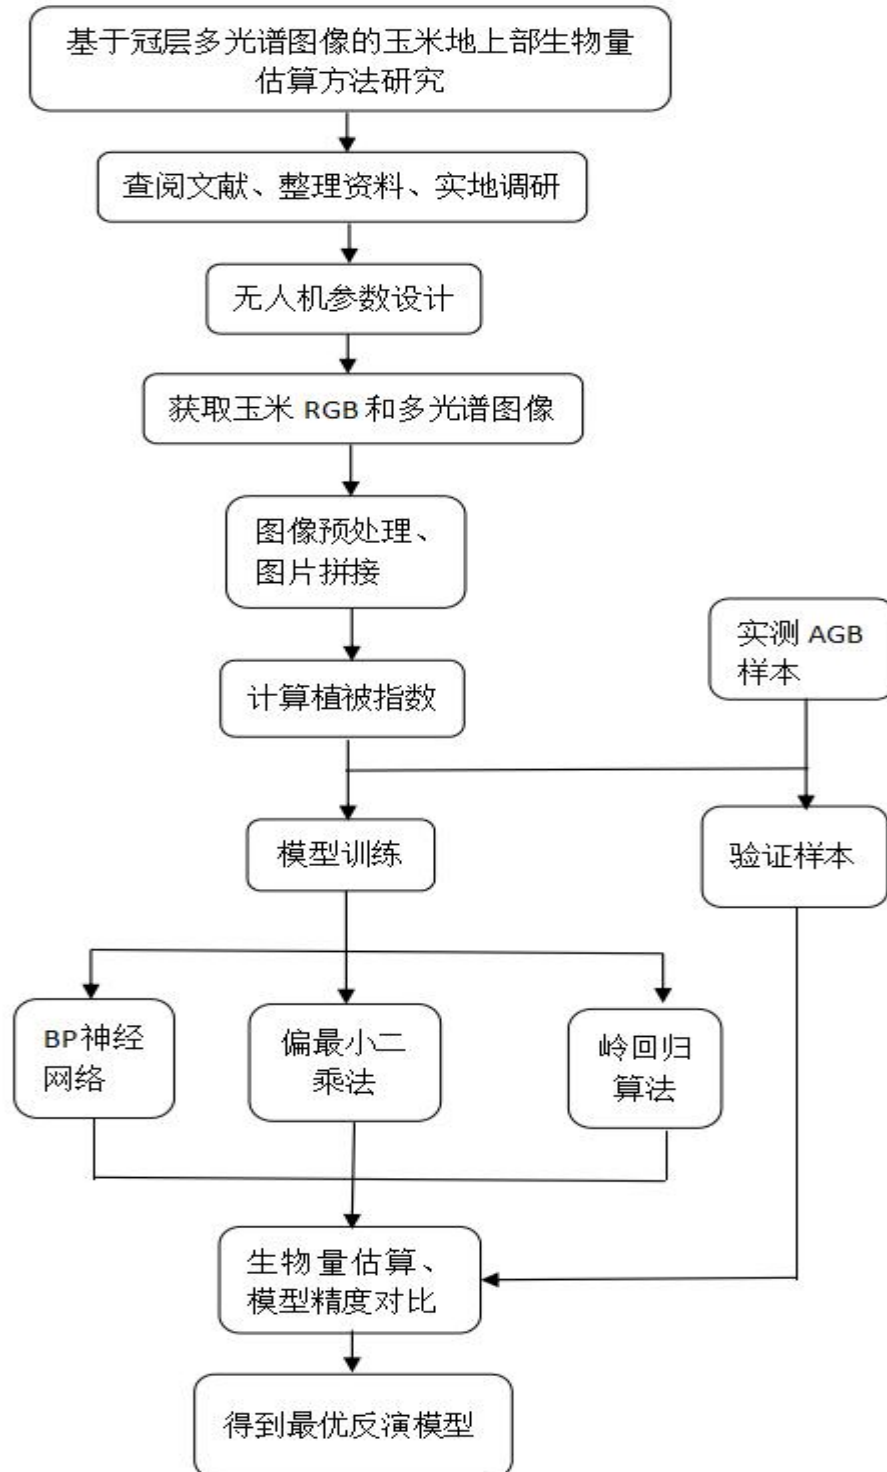


图 1-1 技术线路图

Figure 1-1 Technical circuit diagram

## 1.4 全文的组织结构

论文主要进行基于冠层多光谱图像的玉米地上部生物量估算方法研究，基于以上研究内容，本文共分为七章，论文章节安排如下：

第1章：绪论。本章主要探讨了玉米地上部生物量估算研究的背景和意义，并详细概述了国内外对玉米地上部生物量估算的研究进展和现状。同时，本章还对现有研究的局限性进行了分析，并明确了本文的研究内容，阐述了本文的组织结构和各章节的安排。

第2章：实验设计与理论基础。主要介绍本研究进行实验的试验区概况和相应的实验设计，包括在试验场地布置的实验。通过大疆精灵4多光谱无人机设计航线进行飞行任务，对拔节期、吐丝期、灌浆期获取的实测数据以及光谱数据进行处理，还有相应的植被指数选取。最后是介绍本文应用的模型，BP神经网络、偏最小二乘法、岭回归算法的原理以及模型精确度的检验。

第3章：基于偏最小二乘法模型的地上部生物量反演模型研究。主要介绍研究区玉米地上部生物量分布特征，采用大疆精灵4多光谱无人机获取高分辨率多光谱图像，并提取常见的几种植被指数，包括NDVI、RVI、EVI、DVI以及OSAVI。同时，结合地面实测数据，测量玉米地上部生物量(AGB)，并在二者之间进行相关性分析。根据相关性分析结果，采用偏最小二乘法模型，对比分析实测值与预测值的结果，选取出最优的估算模型。

第4章：基于岭回归算法模型的地上部生物量反演模型研究。主要介绍在第三章的单一植被指数与地上部生物量进行预测的基础上，研究多种植被指数糅合在一起对于地上部生物量的产生的影响。通过岭回归算法建立预测模型，并得到最优估算模型。

第5章：基于BP神经网络算法的地上部生物量反演模型研究。主要介绍BP神经网络算法的地上部生物量反演模型。该模型利用数学方法和优化技术来提高模型的准确度，使用BP神经网络算法对整个观测期的数据进行训练和预测。在训练过程中，将五种植被指数融合作为输入层神经元，得到地上部生物量作为输出参数，并得到最优的估算模型。

第6章：各模型精度对比分析。主要介绍各个模型精度的对比，得出不同生育期不同植被指数的最优估算模型。

第7章：总结与展望。主要介绍本文的研究内容及实验结果，并提出方案中存在的不足，提出可能的解决方案，指出今后的发展趋势和可能的研究方向。



## 第2章 试验设计与理论基础

### 2.1 试验区概况

本研究试验开始于2022年10月，结束于2023年4月，以不同时期的玉米为研究对象。实验研究区域在云南省楚雄州双柏县爱尼山乡（102° 53' E，24° 38' N，海拔883m）和云南省德宏州芒市勐戛镇（98° 40' E，24° 25' N，海拔1370m）两个地方的玉米实验基地进行。爱尼山乡位于双柏县西南部，属北亚热带季风气候区，具有冬干夏湿，气温日差较大，年差较小；冬无严寒、夏无酷暑；干湿季分明，雨热同季；日照充足，霜期较短，冬季降水偏少。年降雨量为864毫米，年极端最低气温6℃，年极端最高气温25℃。实验区域土壤为沙壤土，其PH值为7.27，有机质含量为16.9g/kg，碱解氮为72.1mg/kg，速效磷15mg/kg，速效钾为91.3mg/kg。勐戛镇位于芒市南部，有日照时间长、雨量充沛、冬季多雾等特点。年降雨量为1654.6毫米，年极端最低气温-0.6℃，年极端最高气温36.2℃。实验区域土壤的PH值为7.14，有机质含量为16.8g/kg，碱解氮为184.3mg/kg，速效磷31.1mg/kg，速效钾为185mg/kg。研究区域实验站点分布如图2-1(a)所示，具体大田玉米试验区如图2-1(b)。

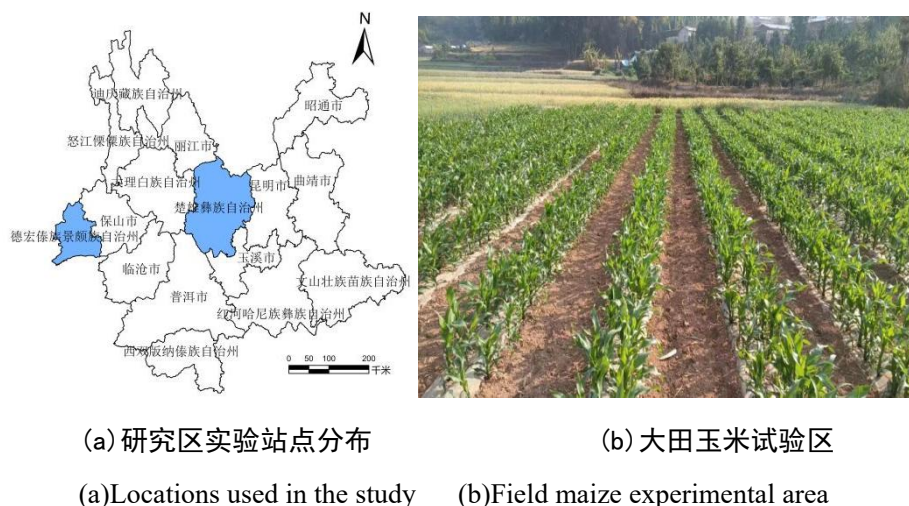


图 2-1 试验区图片

Figure 2-1 Picture of the experimental area

试验区所种作物分别为康农2号、富玉2号、北玉1521玉米，都属于青储玉米。选择所示玉米的拔节期、吐丝期和灌浆期进行试验，具体播种时间如表2-1所示。为了排除其它因素的干扰，玉米大田的田间管理遵循正常的农艺程序，并定期除草。

表 2-1 多品种多试点的玉米田间实验设置  
Table.2-1 Maize field test setting with multiple varieties and pilot projects

站点	播种季节	品种	播种时间
楚雄双柏	2022年冬播	康农2号、富玉2号	2022. 10. 15
德宏芒市	2022年冬播	北玉1521	2022. 11. 14

2.2 试验设计

研究区玉米总种植面积为12亩左右，其中德宏研究区每块地设置密度实验，并重复两次，共18个实验区域，密度情况如表 2-2 所示，实验布置情况如表 2-2 所示。本文选择玉米的重要生育阶段：在拔节期(2022年12月12号)、吐丝期(2023年2月6号)、灌浆期(2023年3月20号)展开实验，在此期间，每14天的周期内，对玉米地的生物量进行采集。在每个实验区域内，选取5个均匀分布的点进行地上部生物量采集，共计540个样本作为研究对象。

表 2-2 密度实验表  
Table 2-2 Density experiment table

型号	密度(株/亩)	株距(cm)	行距(cm)
1	3800	70	24
2	4200	70	22.7
3	4600	70	20.7

2.2.1 玉米鲜重测定

为了避免因为时间差异而导致接受的光谱信息不同，玉米鲜重的测量与多光谱遥感影像获取必须同时进行。无人机执行完任务后，在每个感兴趣区域内采用收获法，随机且均匀选取五株玉米的地上部分，共90株，将用图2-2所示的高精度电子称对鲜重以不同的生育期进行统计，单位为g/株，具体统计情况如表 2-3 所示。



图 2-2 高精度电子秤  
Figure 2-2 High-precision electronic scale

表 2-3 不同生育阶段鲜重统计  
Table 2-3 Fresh weight statistics at different growth stages

生育期	样本数	鲜重最小值 (g/株)	鲜重最大值 (g/株)	平均值(g/株)	标准差	方差
拔节期	180	116.98	273.31	195.94	48.89	51.54
吐丝期	180	265.51	574.12	386.91	134.09	149.92
灌浆期	180	868.32	1322.51	1102.99	168.44	188.33

### 2.2.2 玉米干重测定

快速将取样的植株带回实验室，然后把它们的茎和叶子分离开来。接着用自来水将它们洗净，再把它们放在105度下杀青半小时，80℃烘干48小时以上，直到质量恒定再进行称量<sup>[47]</sup>。实验中用于烘干玉米植株获取干重的设备是电热鼓风干燥箱，如图2-3所示，它拥有加热和鼓风两大功能，最高温可达300℃，对于玉米植株有良好的烘干效果。可以计算出单位面积内的植株生物量。这个方法被广泛应用于植物生态学的研究中，以评估不同生态系统中植物生长的情况，得到每个小区的玉米地上部生物量，并用高精度电子称称量出来<sup>[48]</sup>。地上部生物量计算公式如下：

$$AGB = \frac{M_1 + M_2}{N_1} \times P \quad (2-1)$$

式2-1中， $M_1$ 为茎干重， $M_2$ 为叶干重， $N_1$ 为取样株数， $P$ 为种植密度

称量之后，将所有数据整合，得到干重具体统计情况如表 2-4 所示，可以看出单株玉米在拔节期的地上部生物量在13.04-28.22g/株；在吐丝期的地上部生物量在26.26-73.34g/株；在灌浆期的地上部生物量在155.78-215.25g/株。



图 2-3 电热鼓风干燥箱

Figure 2-3 Electric blast drying oven

表 2-4 不同生育阶段干重统计

Table 2-4 Dry weight statistics at different growth stages

生育期	样本数	干重最小值 (g/株)	干重最大值 (g/株)	平均值 (g/株)	标准差	方差
拔节期	180	12.04	27.22	20.44	4.91	5.17
吐丝期	180	25.35	70.34	43.92	16.17	18.08
灌浆期	180	160.58	215.48	180.35	18.61	20.80

## 2.3 数据获取与预处理

### 2.3.1 数据采集平台

本研究采用的是大疆精灵4多光谱无人机（P4M），如图2-4所示，这款航测无人机配备了一体式多光谱成像系统，可以采集高精度的多光谱数据，有助于高效完成农业监测和环境监察工作。P4M适用于低空摄影测量应用的系统，包含厘米级的导航定位和高性能的成像系统，便携易用，全面提升航测效率。该无人机重1487g，最长飞行时间27min，具备5个用于多光谱成像的单色传感器（红光、红边、蓝光、绿光、和近红外）和1个可见光成像的彩色传感器，有效像素208万，总像素212万，图像分辨率为1600×1300像素，多光谱镜头如图2-3所示，如表2-5展示了多光谱相机的参数和中心波长的反射率。



(a) 大疆精灵4多光谱无人机 (b) 多光谱镜头

(a) DJI Phantom 4 multispectral drone

(b) Multispectral lens

图 2-4 多光谱采集仪器

Figure 2-4 Multispectral acquisition instrument

表 2-5 多光谱相机波段参数

Table 2-5 Parameters of multispectral cameras and reflectivity of center wavelength

波段编号	波段名称	中心波长 (nm)	波宽 (nm)
1	Blue	450	32
2	Green	560	32
3	Red	650	32
4	Near IR	730	32
5	Red Edge	840	52

### 2.3.2 多光谱数据获取

#### (1) 无人机航线规划路线设计

在无人机进行航线规划并获取图像的过程中，不仅受到无人机飞行高度的影响，还会受到航向重叠率和旁向重叠率等因素的影响，从而导致图像畸变现象<sup>[49]</sup>。为了获得最佳的遥感影像效果，需要在不同的飞行参数下获取遥感影像数据，并在同一时间段进行比较试验，以确保天气条件相同，不受其他条件的干扰<sup>[50]</sup>。具体参数设计如表 2-6 所示。

表 2-6 无人机参数设计

Table 2-6 UAV parameter design

项目	a	b	c
飞行高度 (m)	15	25	35
航向重叠度 (%)	80	70	75
旁向重叠度 (%)	70	70	75


最终确定以下飞行参数，具体拍摄参数如表2-7所示。

表 2-7 无人机多光谱系统拍摄参数

Table 2-7 Shooting parameters of UAV multispectral system

参数	值
拍摄时间(北京时间)	10:00—14: 00
拍摄频率(天)	14
飞行高度(m)	15
航向重叠率(%)	80
旁向重叠率(%)	70
地面分辨率(cm. pixel <sup>-1</sup> )	1.5

在实际的田间地形里，需要根据玉米种植方式来设计合适的航拍路线，以获取精确度更高的遥感图像。依据表2-7的拍摄参数，设计了两种航拍路线，如图2-5所示，图中的航点数为82个，主航线条数为6条。



(a) 楚雄试验地路线 (b) 德宏试验地路线  
(a) Chuxiong test site route (b) Dehong test site route

图 2-5 航线规划路线

Figure 2-5 Route planning route

## (2) 多光谱数据采集

本文多光谱数据采集时间是在2022年11月到2023年4月之间进行的，为了确保多光谱影像的数据质量，实验在晴朗无云的天气条件下拍摄影像。每次采集时间是在当天的 10:00—14:00，无人机在15米的位置<sup>[51]</sup>，多光谱相机进行垂直拍摄执行任务，采集过程如图 2-6 所示，具体的飞行过程如下：

进入无人机控制面板，进行无人机定点，地形规整的情况下，只需要四个点即可，地形复杂的情况可根据实际需要多添加点。

定点完成后，进行路线设置，设置飞行高度、航向重叠率和旁向重叠率。

启动任务，无人机上升，对反射率校正板进行拍摄，接着按照航线规划进行拍摄。

拍摄任务完成，自动返回原地降落。



图 2-6 多光谱数据采集

Figure 2-6 Multispectral data acquisition



### 2.3.3 多光谱数据预处理

#### (1) 影像拼接

在玉米的拔节期、吐丝期、灌浆期进行多光谱数据采集，考虑到拼接失败可能性，一个时间段进行2-3次飞行，共进行了42次多光谱影像数据采集。每次航拍任务能够获得492张原始多光谱影像。拍摄完后，需要采用Pix4D mapper软件对无人机多光谱影像进行拼接，拼接前需要把无关的数据剔除<sup>[47]</sup>，影像拼接过程如图2-7所示。




图 2-7 影像拼接过程图

Figure 2-7 Image stitching process

#### (2) 辐射校正

多光谱图像在采集的过程中，容易受到大气层、太阳辐射角、飞行高度和姿态不稳定等因素的干扰，在传感器接收的整个阶段中会产生反射误差，造成光谱参数不准确。因此，在获得无人机多光谱遥感影像后，需要进行辐射校正，以去除干扰因素，获得作物的真实反射数据。本文采用的辐射校正方法是灰板辐射校正法，也就是通常所说的黑白校正法。该方法使用两块3米×3米的灰板，一块用于消除外界光线的影响，另一块用于校正图像的反射率<sup>[52]</sup>。多光谱图像校正如图2-8所示。

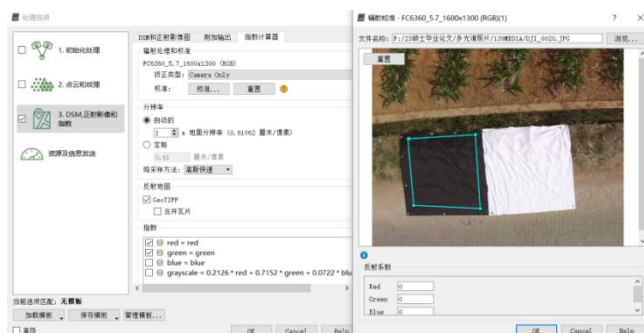
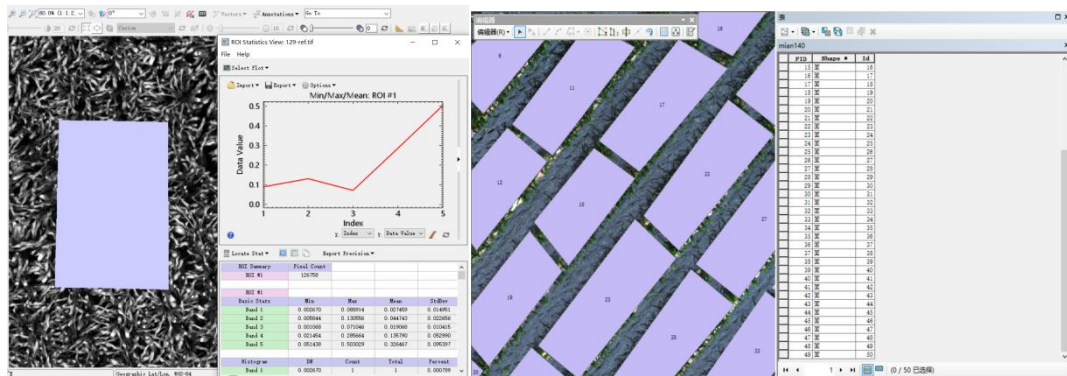


图 2-8 多光谱影像辐射校正

Figure 2-8 Multispectral image radiometric correction

### (3) ROI反射率提取

将黑白校正好的光谱图像导入ENVI 5.3软件中,通过波段运算合成各个植被指数的反射率影像,将每个区域内的方形感兴趣区域(Region of Interest, ROI)(5 m×8 m)尽可能地裁剪,为了排除边行长势不均匀的植株,绘制时应避开小区边界四个方向各一行玉米。这样可以有效提取出每个感兴趣区的平均光谱植被指数。提取感兴趣区域内每个像素点在5个波段上所有的反射率信息,生成光谱曲线,然后计算平均光谱曲线,将其作为该感兴趣区域的光谱数据,如图 2-9(a)所示。接着为所有的感兴趣区域进行编号,如图2-9(b)所示。



(a) ROI反射率提取

(b) ROI编号

(a) ROI reflectivity extraction

(b) ROI number

图 2-9 样本的ROI提取过程

Figure 2-9 ROI extraction of samples

## 2.4 植被指数的选择与提取

植被指数是利用植物叶片的光谱反射率,根据叶绿素含量、叶细胞结构、水分含量等因素,在不同波段上表现出不同的反射光谱特征<sup>[53]</sup>。目前常用的植被指数包括归一化植被指数(NDVI)、差值环境植被指数(DVI)、比值植被指数(RVI)和增强型植被指数(EVI)。其中,NDVI能够估算植被的生理参数,对反映地表植被的生长状况和空间分布密度十分敏感,与植被的多个参数密切相关。DVI能够减少土壤背景对作物的影响,很好地反映植被覆盖度的变化,特别是对土壤背景的变化相当敏感,有利于监测植被生态环境。RVI与地上部生物量AGB、叶面积指数LAI、植被叶绿素含量SPAD相关性较高,在植被覆盖度较高的情况下,对植被比较敏感,与植被生物量的相关性最好。EVI则可以解决植被指数易饱和的问题。

研究者在研究中还使用了其他的植被指数。在2004年,谭昌伟等<sup>[54]</sup>选择了不



同品种的夏玉米进行研究，分析了10种常用的植被指数与叶面积指数（LAI）之间的相关性。结果显示，比值植被指数与叶面积指数之间的精度高达0.9527。在2007年，蒙继华等<sup>[55]</sup>利用农作物叶面积指数的方法，对地上部生物量（AGB）与归一化植被指数（NDVI）进行回归分析，最大相对误差为29%。在2010年，傅银贞等<sup>[56]</sup>运用多光谱遥感数据，对地上部生物量与植被指数等进行反演模型研究，结果表明，NDVI能够很好地反演地上部生物量，并且精度较高。这些研究表明，不同的植被指数在不同情境下具有不同的适用性和精度，可以根据研究目的和研究区域的特点选择合适的植被指数进行应用。

在试验研究中，为了选择合理的用于评估地上部生物量的植被指数，需要考虑外界环境因素的影响，主要包括土壤因素和大气因素。土壤因素包括土壤类型、土壤湿度和土壤覆盖程度等，这些因素可能对植被指数的计算和解释产生影响。大气因素包括大气透过率、大气散射和大气吸收等，这些因素可能对植被指数的测量和解释产生干扰。最终，本文选取了5种常用的植被指数进行研究，它们分别是NDVI、RVI、DVI、OSAVI和EVI。这些植被指数的具体计算公式如表2-8所示。

表 2-8 植被指数  
Table 2-8 Vegetation index

植被指数	计算公式	参考文献
归一化差值植被指数(NDVI)	$(\rho_{NIR} - \rho_R) / (\rho_{NIR} + \rho_R)$	田振坤等 <sup>[57]</sup> 人 (2013年)
增强型植被指数(EVI)	$2.5(\rho_{NIR} - \rho_R) / (\rho_{NIR} + 6\rho_R - 7.5\rho_B + 1)$	Yulin Zhan等 <sup>[58]</sup> 人 (2018年)
优化土壤调节植被指数(OSAVI)	$(1 + 0.16)(\rho_{NIR} - \rho_R) / (\rho_{NIR} + \rho_R + 0.16)$	Rondeaux G等 <sup>[59]</sup> 人 (1996年)
差值植被指数(DVI)	$\rho_{NIR} - \rho_R$	张艳楠等 <sup>[60]</sup> 人 (2012年)
比值植被指数(RVI)	$\rho_{NIR} / \rho_R$	刘姣娣等 <sup>[61]</sup> 人 (2011年)

注：  $\rho_{NIR}$ 、 $\rho_R$ 、 $\rho_B$ 和 $\rho_G$ 分别表示近红外波段、红波段、蓝波段和绿波段的反射率

提取植被指数可以使用ENVI 5.3软件，输入对应的公式进行波段运算，得到相应的灰度图。具体结果如图2-10所示，图中以云南省德宏州芒市勐戛镇玉米试验地

为例。




图 2-10 玉米冠层无人机多光谱植被指数图像

Figure 2-10 Multispectral vegetation index image of maize canopy UAV

## 2.5 相关方法理论基础

### 2.5.1 偏最小二乘算法

偏最小二乘法 (Partial Least Squares, PLS) 是由 Wold 和 Krishnaiah 等人提出的多元线性分析方法，是光谱研究中常用的数学模型<sup>[62]</sup>。偏最小二乘回归 (PLSR) 是一种多元统计方法，旨在通过最小平方误差来寻找最佳匹配函数，以建立数据回归模型<sup>[63]</sup>。即使自变量之间存在高度相关性，PLSR 也可以进行回归建模，并且还允许变量数量大于样本数量的情况。PLSR 的关键参数是潜在因子 (LVs)，通常使用交叉验证方法进行选择<sup>[64]</sup>。由于 PLSR 集成了多元线性回归和主成分分析方法的优点，因此在光谱建模中是最广泛使用的线性回归模型分析方法之一。PLSR 算法计算流程如下：

(1) 对光谱矩阵及理化值矩阵进行因子分解，求解得分矩阵  $T$  和  $U$ 。

$$X = TP + E \quad (2-2)$$

$$Y = UQ + F \quad (2-3)$$

式2-2和2-3中, P, Q 分别为X和Y的载荷矩阵, E和F分别为模型拟合X和Y时的误差。

(2)对T和U进行多元线性回归, 求解矩阵B。

$$U = TB \quad (2-4)$$

$$B = (T^T T)^{-1} T^T Y \quad (2-5)$$

上式中, B为PLS的回归系数矩阵。

(3)对测试集样本进行检测时, 先计算测试集样本的光谱矩阵XP的得分矩阵, 再根据式2-6求得测试集样本的检测值 $Y_p$ 。

$$Y_p = T_p B Q \quad (2-6)$$

### 2.5.2 岭回归算法

岭回归(Ridge Regression)是一种用于处理共线性数据的偏向估计回归方法, 也被称为Tikhonov正则化。岭回归是一种优化的最小二乘估计方法, 用于解决在回归问题中可能出现的过拟合(overfitting)和多重共线性(multicollinearity)问题。相对于传统的偏最小二乘法, 岭回归在损失部分信息和降低精度的代价下, 可以获得更符合实际和更可靠的回归系数。岭回归主要解决两种问题: 一是当预测变量的数量超过观测变量的数量时(预测变量相当于特征, 观测变量相当于标签), 二是数据集之间具有多重共线性, 即预测变量之间具有相关性<sup>[65]</sup>。

岭回归算法计算流程如下:

(1)假设有N个玉米生物量样本点 $\{x, y\}$ , 每个样本点的自变量有M个 $\{x_1, x_2, \dots\}$ , 其中x, y分别对于反射率和波长。如式子2-7, L2范数正则化损失函数, 加上了一个w向量的L2-范数的平方作为惩罚项(L2-范数的含义为向量W每个元素的平方和然后开平方), 其中 $\lambda$ 表示惩罚项的系数。

$$\text{Cost}(w) = \sum_{i=1}^N (y_i - w^T x_i)^2 + \lambda \|w\|_2^2 \quad (2-7)$$

(2)对式子2-7的自变量反射率 $y_i$ 及波长 $x_i$ 进行因子分解, 求解得Cost(w)后, 再经过运算得到下式2-8, 得到最小数的W的大小。

$$w = \operatorname{argmin}_w \left( \sum_{i=1}^N (y_i - w^T x_i)^2 + \lambda \|w\|_2^2 \right) \quad (2-8)$$

(3)然后代价函数通过求导直接得到w的解析解(2-9), 其中X为N x M矩阵,  $\lambda$ 属于实数集, y为N维列向量, 如式子2-10所示, 。

$$W = \left( X^T X + \lambda I \right)^{-1} X^T Y \quad \lambda \in R \quad (2-9)$$

$$X = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_N^T \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1M} \\ X_{21} & X_{22} & \cdots & X_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ X_{N1} & X_{N2} & \cdots & X_{NM} \end{bmatrix} \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} \quad (2-10)$$

### 2.5.3 BP神经网络

BP (Backpropagation) 神经网络是一种多层前馈神经网络模型, 由Rumelhart和McClelland等科学家于1986年提出。它通过梯度下降法的思想, 在训练过程中通过最小化实际输出与期望输出之间的均方差误差来进行模型参数的调整。BP算法包含两个主要的过程: 前向传播和反向传播。经过反复的前向传播和反向传播过程, BP神经网络通过调整权重和阈值来不断优化模型参数, 使网络能够逼近期望的输出。最终, 当网络参数调整到使误差达到最小值时, 模型训练完成, 可以用于进行预测和分类任务<sup>[66]</sup>。

BP神经网络通常是一种具有三层或更多层神经元的多层网络。它的每个神经元在左右两层之间实现全连接, 即左层的每个神经元都与右层的每个神经元相连, 但上下相邻的层之间没有连接。典型的网络包括输入层、隐藏层 (也称中间层) 和输出层。输入层是网络与外界交互的接口<sup>[67]</sup>, 用于存储输入矢量。输入层不对输入矢量进行任何加工和处理。输入层的神经元数目可根据问题和数据表示的方式确定。通过隐藏层, 任何一个连续函数在闭区间内都可以被逼近, 并且一个包含三层的网络可以完成多维映射。对于多层神经网络, 需要确定网络的层数。常用的网络有三层或更多层, 也有只有两层的网络, 即将输入层直接连接到输出层。这种结构只在输入和输出模式非常相似的情况下可行。当输入和输出模式不同时, 需要在输入层和输出层之间增加一个中间层, 也就是隐含层, 用于转换输入信号<sup>[68]</sup>。本研究通过BP神经网络设置了五个植被指数为输入层, 进而为了提高精度。

由一层或多层组成和输出层, 其结构如图2-11(a)所示, BP神经网络中的神经元结构图2-11(b)所示,  $x_1 \sim x_n (1, 2, 3, \cdots, n)$  为输入信号,  $(1, 2, 3, \cdots, n)$  为权重,  $b$  为偏置,  $\Sigma$  为求和节点,  $\sigma$  为激活函数。按照Kolmogorov定理, 单隐层的BP神经网络将能够无限接近任意连续的非线性曲线。但过分拟合会导致模型的泛化能力差, 所以

在实际的应用中还要结合样本本身的特性来控制拟合程度。




图 2-11 BP神经网络介绍

Figure 2-11 Introduction to BP neural networks

BP神经网络具体算法步骤如下：

(1) 网络的初始化

假设一个神经网络模型中，输入层有 $n$ 个节点，隐含层有 $l$ 个节点，输出层有 $m$ 个节点。输入层到隐含层的权重为 $\omega_{ij}$ ，隐含层到输出层的权重为 $\omega_{jk}$ ，输入层到隐含层的偏置为 $a_j$ ，隐含层到输出层的偏置为 $b_k$ 。学习速率为 $h$ ，激活函数为Sigmoid函数 $g(x)$ ，形式如2-11式：

$$g(x) = \frac{1}{1 + e^{-x}} \quad (2-11)$$

(2) 隐含层的输出，如图2-11 (a) 的三层BP网络所示，隐含层的输出 $H_j$ 为：

$$H_j = g\left(\sum_{i=1}^n \omega_{ij} x_i + a_j\right) \quad (2-12)$$

(3) 输出层的输出，将式子2-12带入得：

$$O_k = \sum_{j=1}^l H_j \omega_{jk} + b_k \quad (2-13)$$

(4) 预测误差的计算，这里取误差公式为：

$$E = \frac{1}{2} \sum_{k=1}^m (Y_k - O_k)^2 \quad (2-14)$$

(5) 其中 $Y_k$ 为期望输出。记 $Y_k - O_k = e_k$ ，则 $E$ 可以表示为：

$$E = \frac{1}{2} \sum_{k=1}^m e_k^2 \quad (2-15)$$

以上公式中,  $i=1\cdots n$ ,  $j=1\cdots l$ ,  $k=1\cdots m$ 。

(6) 权值的更新

$$\omega_{ij} = \omega_{ij} + \eta H_j (1 - H_j) x_i \sum_{k=1}^m \omega_{jk} e_k \quad (2-16)$$

$$\omega_{jk} = \omega_{jk} + \eta H_j e_k \quad (2-17)$$

(7) 偏值的更新

$$a_k = a_k + \eta H_j (1 - H_j) \sum_{k=1}^m \omega_{jk} e_k \quad (2-18)$$

## 2.6 模型精确度的检验

(1) 均方根误差

均方根误差 (RMSE) 也称作标准误差, 它可以反映测量数据的准确度, 对于实验数据中的极大或极小值非常敏感。在这项研究中, 使用均方根误差来评估构建模型的精度, 以模型精度的大小来说明不同地区地上部生物量之间的差异。RMSE值越小, 说明模型的精度越高, 因此预测效果会更好。均方根误差的计算公式表示为:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_j)^2}{n}} \quad (2-19)$$

(2) 归一化均方根误差

归一化均方根误差 (NRMSE) 在描述模型验证精度时一般会给定界定范围 NRMSE<10%为估测值和实测值一致性极好,  $10\% \leq NRMSE < 20\%$ 一致性为好,  $20\% \leq NRMSE < 30\%$ 一致性为中等,  $NRMSE \geq 30\%$ 一致性较差。归一化均方根误差的计算公式表示为:

$$NRMSE = \frac{\sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_j)^2}{n}}}{\bar{y}} \quad (2-20)$$

式中:  $y$ 表示因变量;  $\bar{y}$ 表示因变量均值;  $n$ 表示样本个数。

(3) 决定系数

两者之间的相关程度可以通过决定系数大小来反映。当决定系数 $R$ 接近1时, 表示所得到的相关方程具有很高的参考价值, 可以用来衡量玉米地上部生物量反演模

型的估测效果。其表达式为:

$$R^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \times (y_i - \bar{y})^2}{\sum_{i=1}^n (x_i - \bar{x})^2 \times \sum_{i=1}^n (y_i - \bar{y})^2} \quad (2-20)$$

其中 $x_i$ 为AGB的实测值,  $\bar{x}$ 为AGB的实测均值,  $y_i$ 为AGB的预测值,  $\bar{y}$ 为AGB的预测均值,  $n$ 为AGB的选取建模样本的数量。

#### (4) 均方误差

这个统计参数是预测数据和原始数据对应点误差的平方和的平均值。它的数值反映了预测模型的准确性。数值越小, 说明预测模型的准确性越高, 构建的模型效果越好, 得出的玉米地上部生物量值更加精确。其计算公式为:

$$MSE = \frac{1}{n} \sum_{i=1}^m w_i (y_i - \hat{y}_i)^2 \quad (2-21)$$

其中 $n$ 为样本个数。

#### (5) 预测精度

预测精度是指预测误差分布的离散程度, 其大小主要受到模型结构稳定性和实际测量数据的精确性等因素的影响。预测精度越高, 表示构建的预测模型越准确, 从而得到的玉米地上部生物量估算结果也更加精确。其计算公式为:

$$PA = \left( 1 - \frac{RMSE}{\bar{m}} \right) \times 100\% \quad (2-22)$$

#### (6) 准确率

准确率是指在所有被检测为正样本的结果中, 真正的正样本所占的比例。准确率可以反映模型对负样本的区分能力, 当准确率接近1时, 说明模型的区分能力较高, 即模型能够准确地将负样本识别为负样本。其计算公式为:

$$ACC = \frac{TP + TN}{TP + FP + FN + TN} \times 100\% \quad (2-23)$$

#### (7) 召回率

召回率(也称为灵敏度、真正率)是指在整个数据集中真正为正样本的结果中被检测到的正样本所占的比例。召回率可以体现模型对正样本的识别能力, 当召回率接近1时, 说明模型对正样本的识别能力较高, 即模型能够较好地识别出真正的正

样本。其计算公式为：

$$Recall = \frac{TP}{TP + FN} \times 100\% \quad (2 - 24)$$

式中，TP为正类样本预测为正类的个数；FP为负类样本判别为正类的个数；FN为正类样本预测为负类的个数；TN为负类样本判别为负类的个数。

## 2.7 本章小结

本章节主要介绍了试验区概况、实验设计、数据获取及预处理方法、植被指数的选取、模型简介以及模型精确度检验方法等七个部分进行了介绍。通过P4M搭载的五波段多光谱相机，根据已设置好的飞行航线进行光谱数据的采集。接着进行烘干实验和光谱数据的预处理。通过波段运算合成各个植被指数的反射率影像，并提取相应的反射率数据。而后又在模型简介部分，对研究中所用到的偏最小二乘法等模型的原理及特点进行了简述；最后在模型结果分析部分，对适合的方法进行了介绍。



### 第3章 基于偏最小二乘法模型的地上部生物量反演模型研究

偏最小二乘法模型是一种经验性的统计与描述方法，可用于观测数据的分析处理。该模型结构简单、适用性强、具备多元线性回归和主成分分析方法，是一种较为合适的玉米地上部生物量指数反演方法，可用于光谱建模<sup>[69]</sup>。本章基于无人机多光谱遥感技术，并利用15米高度获取的大田玉米的多光谱图像数据。通过使用Python编程语言，构建了一个基于偏最小二乘法模型的地上部生物量反演模型。模型的输入量包括从光谱图片获取的反射率和波长，输出量为地上部生物量。研究的重点是对单一植被指数进行地上部生物量反演模型的研究。

#### 3.1 基于偏最小二乘法模型的参数优化

在进行单一植被指数与地上部生物量建模的过程中，需要对各个感兴趣区域进行五波段的反射率提取，以作为输入参数。因各波段反射率存在最大值max，最小值min，所以经过计算，采用平均反射率。经过处理后部分感兴趣区域各波段的平均反射率如表3-1所示：

表 3-1 部分ROI区域各波段的平均反射率

Table 3-1 Average reflectivity of each band in a partial ROI region

区域编号	blue	blgreenue	red	redeage	nir
1	0.317324752	0.19536455	0.105756091	0.142960423	0.158709478
2	0.420934558	0.099046631	0.107950821	0.148891554	0.166541813
3	0.232346502	0.50625754	0.118032304	0.756972876	0.67187033
4	0.140086678	0.113019861	0.821292365	0.165641607	0.18331354
5	0.534960213	0.109923063	0.120478751	0.362433269	0.779143708
6	0.647270126	0.818591062	0.328792254	0.173069821	0.190533678
7	0.146636576	0.117954034	0.426246987	0.171096275	0.589010209
8	0.41805338	0.698955628	0.108931393	0.352812779	0.172874075
9	0.128388254	0.106531978	0.612403293	0.259400436	0.480456171
10	0.733578467	0.110420181	0.120854954	0.163754583	0.181690871

#### 3.2 基于偏最小二乘法模型的建模分析

本章探讨了玉米在不同生长阶段的地上部生物量反演模型。分别建立了玉米拔节期、吐丝期以及灌浆期这三个阶段的植被指数与地上部生物量之间的偏最小二乘法模型。对玉米的光谱图像进行了不同时期的处理和比较，得到相应反射率，获得了不同生长阶段内最优的地上部生物量反演研究成果。

### 3.2.1 玉米拔节期地上部生物量建模分析

通过在玉米拔节期采集的数据，提取想要的植被指数NDVI、RVI、OSAVI、DVI、EVI，将对应的反射率分别与AGB建立偏最小二乘法模型，180个样本中，选择其中108个样本建模，去掉异常值，得到结果如图3-1所示。从图中可以得出，在玉米拔节期，反射率越高对应的玉米地上部生物量就越高，但相对散点图比较分散，说明光谱数据还是受到了大气和土壤的影响。五种植被指数-AGB模型的决定系数都在0.652以上，其中最高的两个模型是NDVI-AGB、RVI-AGB模型，决定系数分别为0.756、0.745，说明归一化植被指数和比值植被指数与地上部生物量之间存在良好的相关性，并且比值植被指数在预测生物量上具有优势。

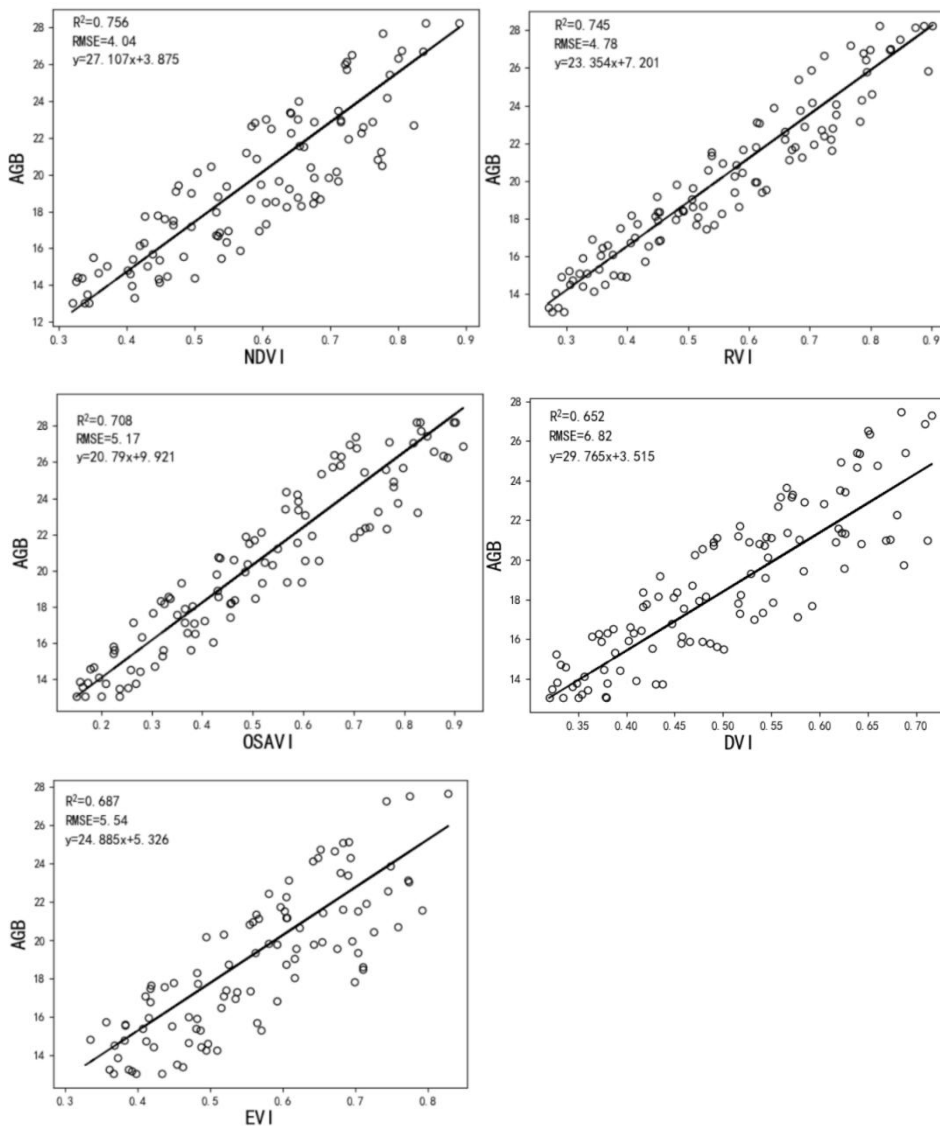


图 3-1 各植被指数与地上部生物量模型

Figure 3-1 Individual vegetation indices and aboveground biomass models

### 3.2.2 玉米吐丝期地上部生物量建模分析

在玉米的吐丝期，将五种植被指数NDVI、RVI、OSAVI、DVI、EVI分别与AGB建立偏最小二乘法模型进行模型建模，180个样本中，选择其中108个样本建模，去掉异常值，得到结果如图 3-2 所示。从图中可以得出，在玉米吐丝期，普遍测得的生物量要比拔节期要高。同时，得到的五种植被指数-AGB模型的的决定系数在0.733以上，其中EVI-AGB的决定系数最高为0.883，说明增强型植被指数与地上部生物量之间存在良好的相关性。

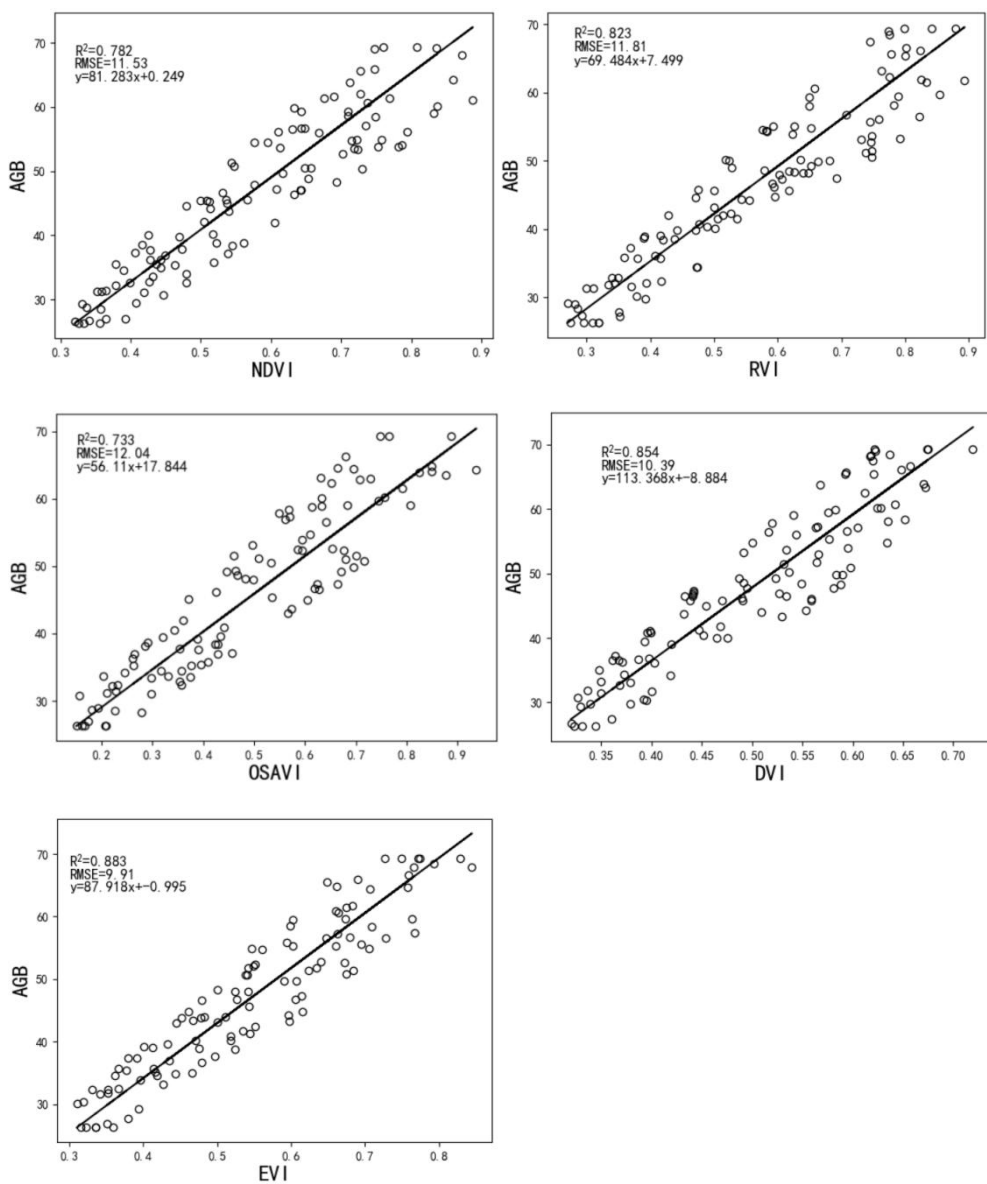


图 3-2 各植被指数与地上部生物量模型

Figure 3-2 Individual vegetation indices and aboveground biomass models

### 3.2.3 玉米灌浆期地上部生物量建模分析

在玉米灌浆期，进行地上部生物量建模分析，灌浆期的玉米植被覆盖度较高，受土壤因素影响较小，相比于拔节期和吐丝期模型表现效果要好一些。对提取的各植被指数NDVI、RVI、OSAVI、DVI、EVI分别与AGB建立偏最小二乘法模型，180个样本中，选择其中108个样本建模，去掉异常值，得到结果如图 3-3 所示。从图中可以得出，在玉米灌浆期，得到五种植被指数-AGB模型的决定系数都在0.697以上，其中两种偏高的是NDVI-AGB、RVI-AGB模型，决定系数分别为0.881和0.894，说明归一化植被指数和比值植被指数与地上部生物量反演存在良好的相关性。

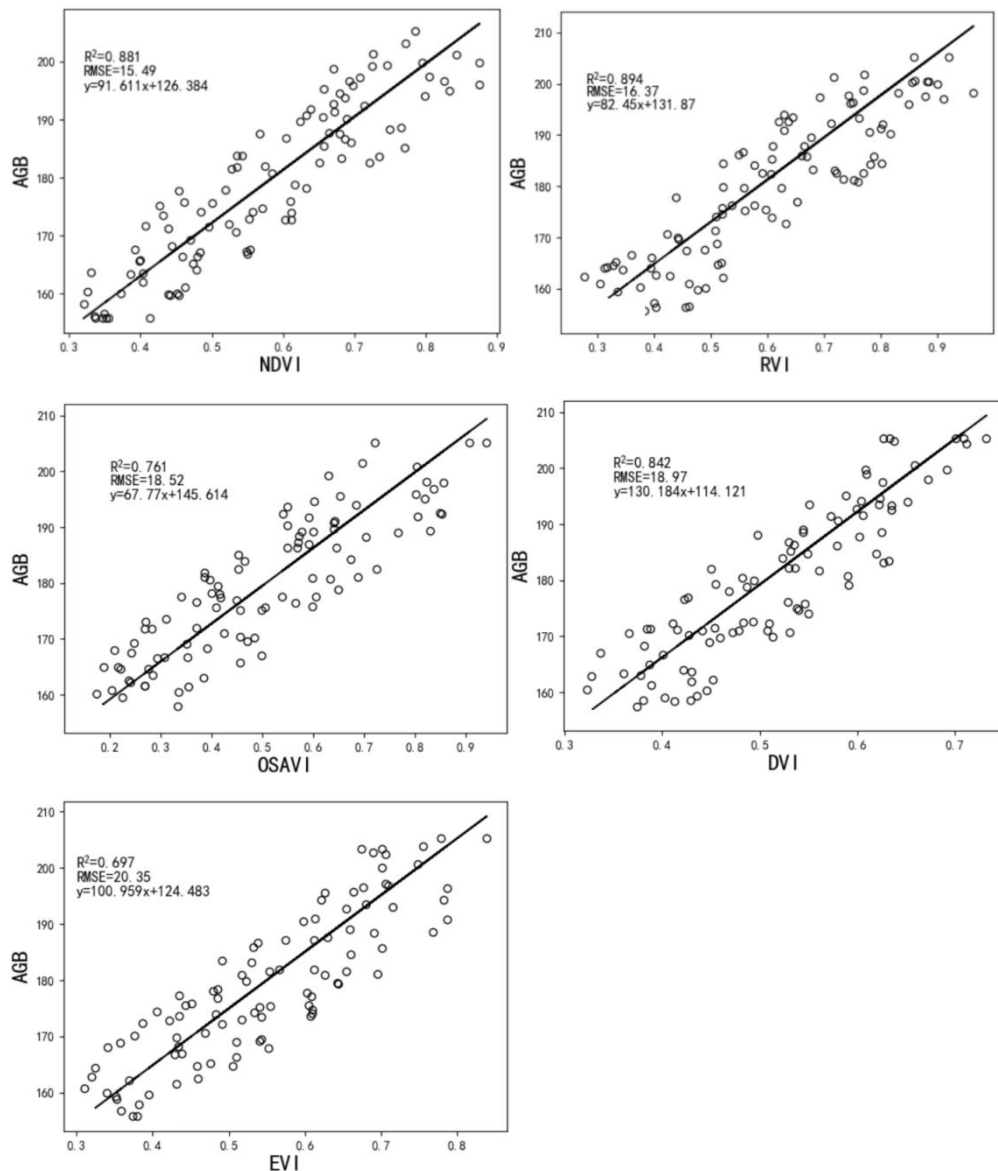


图 3-3 各植被指数与地上部生物量模型

Figure 3-3 Individual vegetation indices and aboveground biomass models

为了更好地比较所构建模型，体现因植被指数不同产生的区别和差异。现在将所有感兴趣区域的植被指数和地上部生物量(AGB)所建立偏最小二乘法模型整理，具体结果如表3-2所示。

表 3-2 不同时期模型精度

Table 3-2 Model correlations over time

生育时期	统计量	NDVI	RVI	OSAVI	DVI	EVI
拔节期	$R^2$	0.756	0.745	0.708	0.652	0.687
	RMSE ( $\text{g}/\text{m}^2$ )	4.04	4.78	5.17	6.82	5.54
	NRMSE (%)	20.20	21.72	23.46	34.12	27.70
吐丝期	$R^2$	0.782	0.823	0.733	0.854	0.883
	RMSE ( $\text{g}/\text{m}^2$ )	11.53	11.81	12.04	10.39	9.91
	NRMSE (%)	23.06	23.62	24.08	18.26	22.02
灌浆期	$R^2$	0.881	0.894	0.761	0.842	0.697
	RMSE ( $\text{g}/\text{m}^2$ )	15.49	16.37	18.52	18.97	20.35
	NRMSE (%)	12.12	19.74	27.04	23.94	29.33

根据表格3-2所示数据，对各生育期的植被指数（NDVI、EVI、DVI、RVI、OSAVI）和AGB系数进行比较后，发现在所有感兴趣的区域内：拔节期的NDVI-AGB建模精度、吐丝期的EVI-AGB建模精度以及灌浆期的RVI-AGB建模精度均高于其他四种植被指数的建模精度，但这种差别不是非常明显。值得注意的是，在灌浆期，RVI-AGB的决定系数 $R^2$ 为0.894、RMSE为 $16.37\text{g}/\text{m}^2$ 、NRMSE为19.74%，建模精度显著高于其他四种植被指数的相关性，且NRMSE<20%，具有良好的一致性，整体精度较高。原因在于，RVI与AGB、LAI、SPAD在植被覆盖度较高时，对植被比较敏感，与植被生物量的相关性要好。该指数利用植被在红光和近红外波段的反射光谱差异，凸显植被与土壤背景之间的辐射差异。其中拔节期DVI-AGB模型决定系数 $R^2$ 为0.652、RMSE为 $6.82\text{g}/\text{m}^2$ 、NRMSE为34.12%，建模精度最小，且NRMSE>30%，一致性较差。主要原因是在灌浆期由于地上部生物量处于迅速增长期，而差值植被指数DVI是对土壤背景的变化相当敏感，受到土壤背景的影响大，所以其相关性偏小。

### 3.3 基于偏最小二乘法模型的模型检验

为了证明所建模型的可靠性和普适性，需要进行精度评价，以下介绍基于偏最小二乘法的AGB模型检验。理想的监测模型应该满足简单易懂的数学表达式和显著的

回归方程，因此，在独立样本数据上进行回归分析，可以用来评估构建的玉米地上部生物量（AGB）预测模型的可信度。首先，将实测值和预测值进行比较，并绘制1:1关系图，以便直观地观察实测值和预测值之间的一致性。如果实测值和预测值之间的散点图分布在一条近似的直线上，说明模型的预测效果较好。

### 3.3.1 玉米拔节期地上部生物量模型检验

通过拔节期与偏最小二乘法训练好的模型,从180个样本中，选择其中72个样本进行预测，从而构建模型检验：实测值-植被指数预测值图，得到结果如图3-4所示。

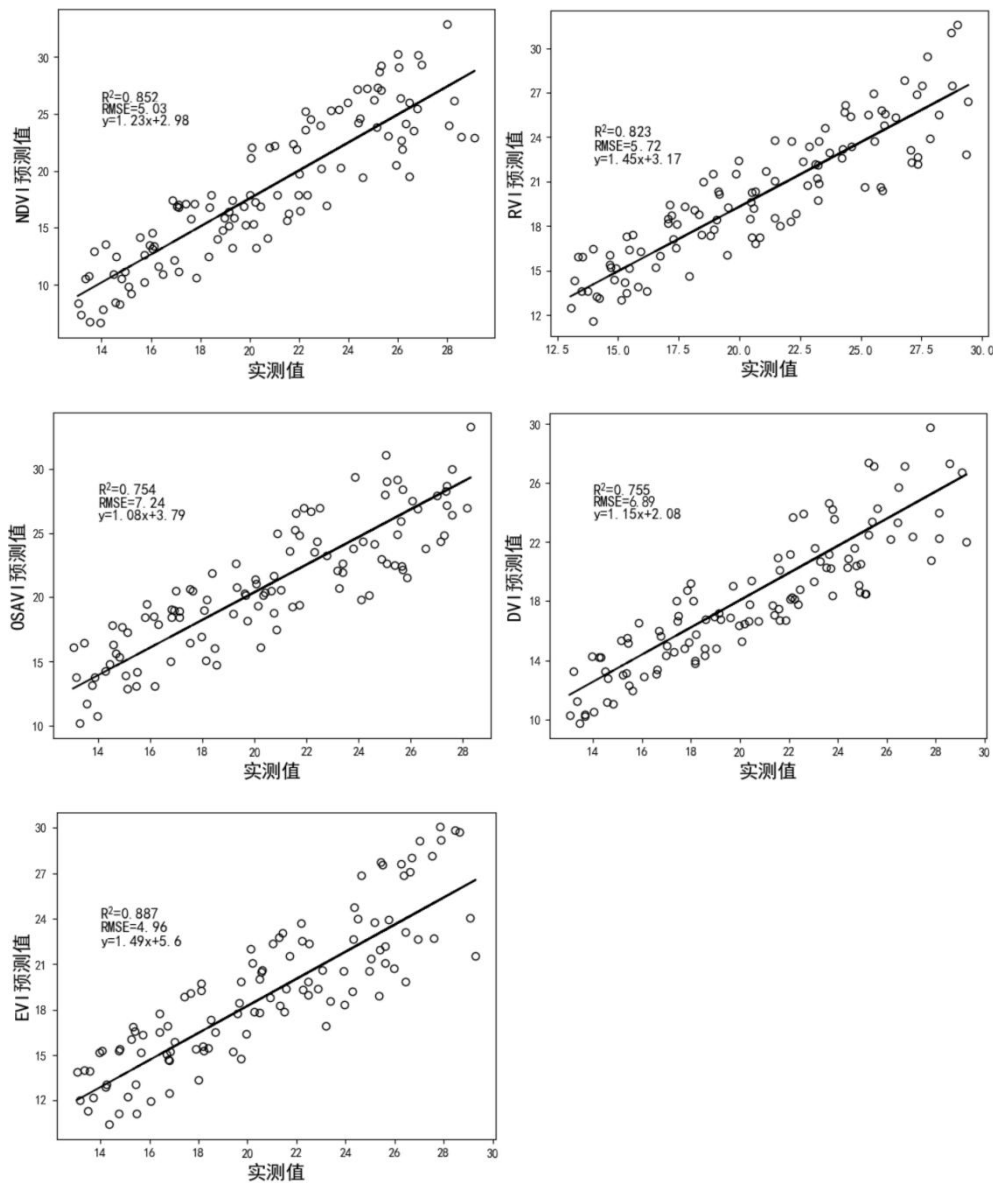


图 3-4 经验模型对预测样本的模型检验

Figure 3-4 Model test of empirical models on prediction samples

由图 3-4 可知各生育期的植被指数(NDVI、RVI、OSAVI、DVI、EVI)在与AGB建

立PLSR预测模型时，所得实测值与预测值的相关性良好，预测值与实测值最大相差30%。五个模型检验中，EVI-AGB回归模型的估测结果较好，其决定系数达到了0.887；OSAVI-AGB相较于其他四个回归模型略差，其决定系数为0.754，也有较好的估测结果，但没有EVI-AGB回归模型的估测结果好，主要原因是增强型植被指数可处理植被指数易饱和的问题。

### 3.3.2 玉米吐丝期地上部生物量模型检验

通过吐丝期与偏最小二乘法训练好的模型,从180个样本中，选择其中72个样本进行预测，从而构建模型检验：实测值-植被指数预测值图，得到结果如图3-5所示。

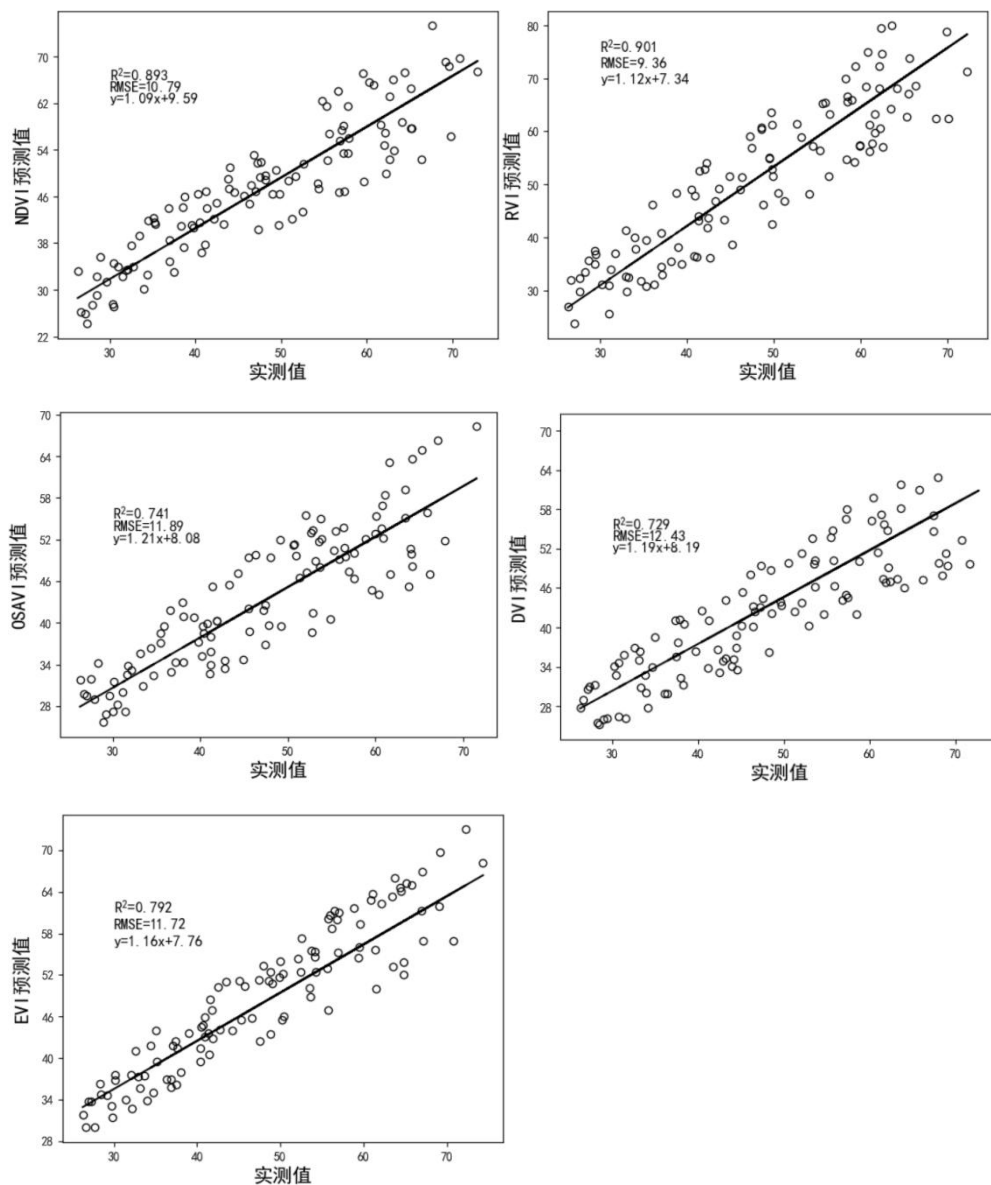


图 3-5 经验模型对预测样本的模型检验

Figure 3-5 Model test of empirical models on prediction samples

由图 3-5 可以得知,在拔节期中,通过偏最小二乘法建立的各种植被指数(包括NDVI、RVI、OSAVI、DVI、EVI)与AGB之间的模型检验比较一致。五种模型中,最优的是RVI-AGB模型, $R^2$ 达到0.901,其中RVI-AGB 回归模型的估测结果较好,其 $R^2$ 达到了0.901,OSAVI-AGB相较于其他四个回归模型略差,其 $R^2$ 为0.741,也有较好的估测结果,但没有RVI-AGB回归模型的估测结果好,原因在于比值植被指数对于生物量的预测比较敏感。

### 3.3.3 玉米灌浆期地上部生物量模型检验

通过灌浆期与偏最小二乘法训练好的模型,从180个样本中,选择其中72个样本进行预测,从而构建模型检验:实测值-植被指数预测值图,得到结果如图3-6所示。

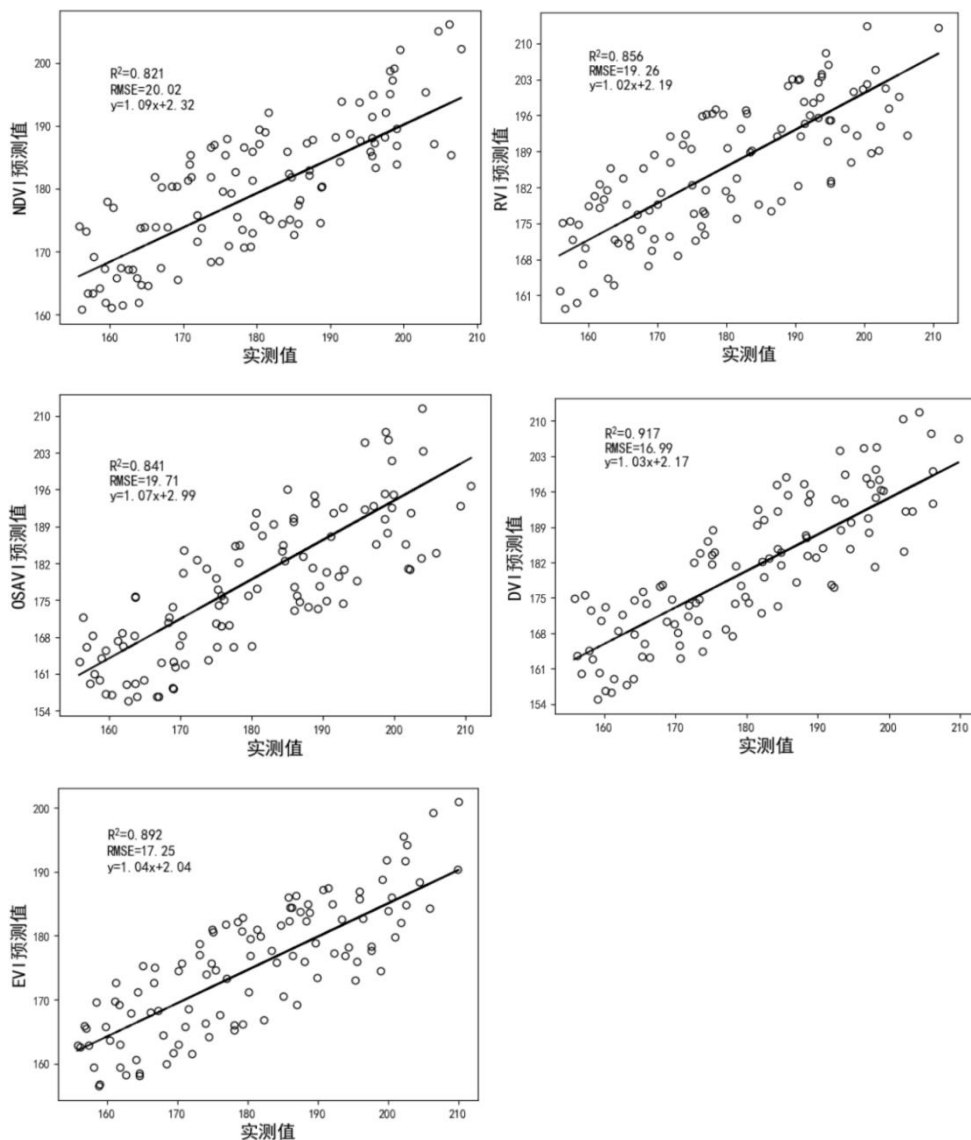


图 3-6 经验模型对预测样本的模型检验

Figure 3-6 Model test of empirical models on prediction samples



由图 3-6 可知在灌浆期的各植被指数 NDVI、RVI、OSAVI、DVI、EVI分别与 AGB 建立偏最小二乘法模型的模型检验中, 实测值与预测值相关性良好。其中, DVI-AGB回归模型的估计结果表现较为出色, 其决定系数达到了0.917。NDVI-AGB相较于其他四个回归模型略差, 其决定系数为0.821, 也有较好的估测结果, 其他几个回归模型也表现良好, 但是没有DVI-AGB回归模型的估计结果好, 原因在于。DVI能够减少土壤背景对作物的影响, 能够很好地反映植被覆盖度的变化, 特别是对土壤背景的变化相当敏感, 有利于监测植被生态环境。

为了能够更为清晰地对比所预测模型的区别与差异, 现将上述所有区域的植被指数与 AGB 的偏最小二乘法预测模型整理, 其结果如表 3-3所示。

表 3-3 遥感监测模型评价结果表

Table 3-3 Table of results of evaluation of non-stress model for remote sensing monitoring

生育时期	统计量	NDVI	RVI	OSAVI	DVI	EVI
拔节期	$R^2$	0.852	0.823	0.754	0.755	0.887
	RMSE(g/m <sup>2</sup> )	5.03	5.72	7.24	6.89	4.96
	NRMSE(%)	16.76	22.88	28.96	32.80	19.84
吐丝期	$R^2$	0.893	0.901	0.741	0.729	0.792
	RMSE(g/m <sup>2</sup> )	10.79	9.36	11.89	12.43	11.72
	NRMSE(%)	20.35	17.01	26.75	31.07	26.04
灌浆期	$R^2$	0.821	0.856	0.841	0.917	0.892
	RMSE(g/m <sup>2</sup> )	20.02	19.26	19.71	16.99	17.25
	NRMSE(%)	22.24	20.70	24.83	28.31	23.54

从表3-3可以得知, 在比较各种植被指数和地上部生物量的实测值与预测值的模型检验时, 发现灌浆期的DVI-AGB模型决定系数 $R^2$ 为0.917, RMSE为16.99g/m<sup>2</sup>, NRMSE为28.31%, 高于其他玉米生育期的植被指数和地上部生物量的模型决定系数。吐丝期的NDVI-AGB和RVI-AGB模型具有较高的决定系数, 而其他三种模型的决定系数要低于这两个。在拔节期, EVI-AGB、RVI-AGB和NDVI-AGB回归模型的决定系数分别为0.887、0.823和0.852, 明显高于其他两种回归模型的决定系数。因此, 在正常浇水施肥的条件下, 通过偏最小二乘法模型可以得出大田玉米地上部生物量的最佳反演植被指数为DVI和RVI。

### 3.4 本章小结

本章基于偏最小二乘法模型，对植被指数与AGB进行了建模分析，并对各个植被指数建立模型检验图，利用决定系数、均方根误差、归一化均方根误差进行精度评价。经过对比分析，拔节期的NDVI-AGB回归模型的 $R^2$ 为0.756、RMSE为4.04g/m<sup>2</sup>、NRMSE为20.20%，吐丝期的EVI-AGB回归模型 $R^2$ 为0.883，RMSE为9.91g/m<sup>2</sup>，NRMSE为22.02%以及灌浆期的RVI-AGB回归模型的 $R^2$ 为0.894，RMSE为16.37g/m<sup>2</sup>，NRMSE为19.74%，模型一致性较好，均有良好表现，经过验证和预测，偏最小二乘法建立的预测值和实测值模型之间具有很好的模型精度。

## 第4章 基于岭回归算法的地上部生物量反演模型研究

第三章重点介绍偏最小二乘模型建立单一植被指数与地上部生物量的关系，并且得到了较好的模型。但是目前还没有研究多种植被指数糅合对地上部生物量的影响。为此，本章采用岭回归作为多种植被指数预测地上部生物量的模型。岭回归是一种专为共线性数据分析而设计的有偏估计回归方法，它用改良的最小二乘估计法代替了偏最小二乘法的无偏性，通过放弃部分信息和降低精度以获得回归系数，从而解决病态矩阵问题，更符合实际和可靠。本章将利用python实现岭回归模型的搭建，研究多种植被指数与地上部生物量之间的关系，并应用此模型进行玉米地上部生物量监测<sup>[70]</sup>。

### 4.1 基于岭回归模型的参数的优化

在进行多种植被指数与地上部生物量建模的过程中，需要对各个感兴趣区域进行不同植被指数的反射率提取，以作为输入参数。因不同植被指数的反射率也存在最大值max，最小值min，所以经过计算，采用平均值avg作为输入参数。反射率需要经过归一化处理，归一化公式如4-1所示：

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (4-1)$$

经过归一化处理后部分感兴趣区域不同植被指数的平均反射率如表4-1所示：

表4-1 部分ROI区域植被指数的平均反射率

Table4-1 Average reflectivity of vegetation index in partial ROI regions

植被 指数	1	2	3	4	5	6	7	8
EVI	0.27540	0.28197	0.26561	0.26957	0.27284	0.27194	0.26756	0.29183
NDVI	0.20527	0.21750	0.19267	0.21006	0.20177	0.20072	0.20472	0.22740
RVI	1.63036	1.70649	1.55589	1.66194	1.61328	1.62330	1.67606	1.73704
OSAVI	0.14465	0.15542	0.13957	0.15475	0.14783	0.14954	0.15241	0.16520
DVI	0.05295	0.05859	0.05384	0.06202	0.05866	0.06174	0.06276	0.06394

在岭回归中，对数正则化参数(lambda,  $\lambda$ )是有偏估计的回归参数。它的作用是通过增加对解的约束，来抑制过拟合问题，并提高模型的泛化能力。当对数正则化参数变大时，残差平方和会增加，但系数检验会变得更好。将五种植被指数(NDVI、RVI、OSAVI、DVI、EVI)，作为岭回归的参数输入，并通过训练，得到岭迹图如图4-1

所示,可以发现当 $\lambda$ 大于2时,岭参数的取值会变得相对稳定,接近于0。因此,可以选择对 $\lambda=2$ 的岭回归系数作为最终权重参数。若 $\lambda$ 值越小,则表明模型越稳定、预测越准确。




图 4-1 岭迹图

Figure 4-1 Ridge trace map

## 4.2 基于岭回归模型的建模分析

### 4.2.1 玉米拔节期地上部生物量建模分析

在感兴趣区域内,利用拔节期所采集数据中提取的各种植被指数(如NDVI、RVI、OSAVI、DVI、EVI),同时与地上部生物量(AGB)建立岭回归模型。共计180个样本,其中108个样本用于建模。结果如图 4-2 所示,在玉米拔节期,多种植被指数与地上部生物量之间的模型决定系数为0.926, RMSE值为 $7.34\text{g}/\text{m}^2$ ,说明岭回归模型与混合植被指数构建的模型具有较好的预测效果。




图 4-2 拔节期岭回归监测模型

Figure 4-2 Ridge regression monitoring model at the jointing stage

#### 4.2.2 玉米吐丝期地上部生物量建模分析

在感兴趣区域内，利用吐丝期所采集数据中提取的各种植被指数（如NDVI、RVI、OSAVI、DVI、EVI），同时与地上部生物量（AGB）建立岭回归模型。共计180个样本，其中108个样本用于建模。结果如图 4-3 所示，在玉米吐丝期，多种植被指数与地上部生物量之间的模型决定系数为0.832，RMSE值为10.69g/m<sup>2</sup>，说明构建的模型具有较好的预测效果。




图 4-3 吐丝期岭回归监测模型

Figure 4-3 Ridge regression monitoring model at the spinning stage

#### 4.2.3 玉米灌浆期地上部生物量建模分析

在感兴趣区域内，利用灌浆期所采集数据中提取的各种植被指数（如NDVI、RVI、OSAVI、DVI、EVI），同时与地上部生物量（AGB）建立岭回归模型。共计180个样本，其中108个样本用于建模。结果如图 4-4 所示，在玉米灌浆期，多种植被指数与地上部生物量之间的模型决定系数为0.834，RMSE值为19.91g/m<sup>2</sup>，说明构建的模型具有较好的预测效果。




图 4-4 灌浆期岭回归监测模型

Figure 4-4 Ridge regression monitoring model at the filling stage

从上述建立的岭回归模型可以得知，在所选感兴趣区域中，多种植被指数和地上部生物量呈良好的线性拟合关系，相较于单一植被指数和地上部生物量的线性关系。这可能是因为玉米生长受到多种条件的影响，包括光照、密度、土壤等因素，而使用多种植被指数可以更全面地反映这些影响，从而提高地上部生物量的反演精度。此外，对比表明，吐丝期多种植被指数与地上部生物量的决定系数仅为0.832， $RMSE=10.69g/m^2$ ，要低于其他时期的模型结果，说明吐丝期这一个关键时期，在岭回归模型中的预测效果不佳。

### 4.3 基于岭回归模型的模型检验

利用独立样本数据对样本的实测值和预测值进行预测，评价指标包括 $R^2$ 和 $RMSE$ 。建立预测值与实测值之间呈现1:1关系的玉米地上部生物量的关系图，以评估模型的可靠程度。使用每个观测阶段的模型进行预测，以得到最佳的反演模型。

#### 4.3.1 玉米拔节期地上部生物量模型检验

在感兴趣的区域内，共有180个样本处于拔节期。其中72个样本被用来进行预测，模型检验如图4-5所示。从图中可以看出，在拔节期中，植被指数（包括NDVI、RVI、OSAVI、DVI和EVI）和AGB之间建立的岭回归模型的模型检验与实际值相当吻合。该模型的决定系数为0.845， $RMSE$ 为 $7.85g/m^2$ ，说明建模效果良好。




图 4-5 拔节期岭回归模型检验

Figure 4-5 Test of ridge regression model at jointing stage

#### 4.3.2 玉米吐丝期地上部生物量模型检验

在感兴趣的区域内，共有180个样本用于吐丝期模型建立，其中72个样本用于预测。模型检验如图4-6所示。从图中可以看出，使用拔节期的各植被指数 NDVI、RVI、

OSAVI、DVI、EVI 与 AGB 建立的岭回归模型能够准确预测实际值，决定系数高达 0.89，RMSE 为  $12.03\text{g/m}^2$ ，说明建模效果良好。




图 4-6 吐丝期岭回归模型检验

Figure 4-6 Test of spinnery ridge regression model

#### 4.3.3 玉米灌浆期地上部生物量模型检验

在感兴趣区域中，共有180个样本用于灌浆期模型。其中72个样本用于预测，得到的结果如图4-7所示。从图中可知，在拔节期的各植被指数（包括NDVI、RVI、OSAVI、DVI、EVI）同时与AGB建立岭回归模型的估测结果中，实测值和预测值具有较好的一致性，其决定系数达到了0.868，RMSE为  $23.98\text{g/m}^2$ ，说明建模效果良好。




图 4-7 灌浆期岭回归模型检验

Figure 4-7 Test of ridge regression model in grouting period

从上述建立的岭回归模型可以得知，在所选感兴趣区域中，多种植被指数和地上部生物量模型检验同样呈良好的线性拟合关系，且也要高于单一植被指数和地上部生物量的线性关系。此外，经过对比发现，拔节期的多种植被指数与地上部生物量决定系数仅为0.845，RMSE为  $7.85\text{g/m}^2$ ，要低于其他时期的模型结果，说明拔节期这一个关键时期，在岭回归模型中的预测效果不佳。但三个生育期的模型结果均达

到了0.845以上，且最高的吐丝期-岭回归模型模型检验良好，决定系数 $R^2$ 为0.89， $RMSE=12.03g/m^2$ ，可以作为预测玉米地生物量的反演模型。

#### 4.4 本章小结

本章通过应用岭回归方法，构建了多种植被指数与地上部生物量之间的线性关系模型，并使用决定系数和均方根误差对模型的预测精度进行了评估。在获取模型输入参数后，建模对比结果表明，拔节期的植被指数-AGB回归模型 $R^2$ 为0.906， $RMSE$ 为 $7.34g/m^2$ ，在三个生育期中表现良好。模型检验对比表明，吐丝期的植被指数-AGB回归模型 $R^2$ 为0.89， $RMSE$ 为 $12.03g/m^2$ ，同样表现良好。在多种植被指数与地上部生物量的建模结果优于单一植被指数与地上部生物量的建模结果，对各生长阶段进行预测验证后，发现实测值和预测值确有较好的一致性，且岭回归算法在吐丝期预测地上部生物量有优势。



## 第5章 基于BP神经网络算法的地上部生物量反演模型研究

BP神经网络能够通过数学方法和优化技术提高模型的精度<sup>[71]</sup>。因此，本章利用BP神经网络对整个观测阶段所采集的数据样本进行训练和预测。在训练时，本章采用第四章4.1节中的反射率数据作为输入量，并结合NDVI、EVI、OSAVI、DVI和RVI这五种植被指数作为模型的5个神经元，利用python实现BP神经网络模型的搭建，并通过模型计算得到地上部生物量作为输出参数。此后，本章进行了108个样本的区域建模以及72个样本的预测，从而对地上部生物量反演模型进行了研究。

### 5.1 基于BP神经网络模型参数优化与训练

#### 5.1.1 模型参数优化

根据模型特点需要自动推导能力以及光谱数据特征性，选择PyTorch作为深度学习的框架<sup>[72]</sup>。在BP神经网络中进行模型参数优化，需要对模型的三层结构进行层数确定。首先是输入层，通过第四章将五种植被指数结合一同作为输入参数进行训练的结果显示，模型表现良好。那么本章选择将五种植被指数融合作为BP神经网络的输入层，即确定输入层为1。

其次是隐含层，该层处于三层结构的中间层，与输入层和输出层一一对应。隐含层神经元个数的选择对模型的精度和训练速率有很大的影响。神经元个数偏多或者偏少，得到的结果都将大不相同。若过多，则会导致模型过拟合，若过少，则会导致模型欠拟合，从而影响模型的预测能力。根据Kolmogorov定理，并参考以下公式，经过相关性计算，得到隐含层神经元的个数为5个，模型性能表现最优。

$$x < a - 1 \quad (5-1)$$

$$x < \sqrt{a+b} + \alpha \quad (5-2)$$

$$x = \log_2 b \quad (5-3)$$

式中，a为输出层神经元个数，b为输入层神经元个数， $\alpha$ 为1-10的常数。

最后是输出层，模型中需要得到的玉米三个时期的地上部生物量(AGB)，所以确定输出层数量为1。

#### 5.1.2 模型训练

通过融合五种玉米植被指数作为输入层神经元，玉米地上部生物量实测值作为

训练目标，设定模型输入层：隐藏层：输出层数量为1：5：1，并将激活函数选取为Sigmoid函数。为了提高训练效率，建模时网络初始参数设置为初始目标精度为0.001，最大迭代次数为100，学习率为0.001。其他参数也选取最优阈值。训练结束后保存训练模型，并用测试集对训练模型进行验证，其中训练集：测试集=6：4。经过训练及结果对比分析本研究最终确定使用设定参数作为识别网络模型参数，检测玉米地上部生物量的准确率、召回率如图5-1所示。




图 5-1 BP神经网络准确率、损失值、召回率结果图

Figure 5-1 BP neural network accuracy, loss value, recall result plot

由图5-1可知，BP神经网络在经过100次迭代周期后，前40次的迭代周期中，损失函数明显减小且趋势变缓。训练集准确率值达到了90.31%，召回率值为86.47%。

## 5.2 基于BP神经网络模型的建模分析

### 5.2.1 玉米拔节期地上部生物量建模分析

在研究区域中，使用采集的拔节期数据提取了多个植被指数，包括NDVI、RVI、OSAVI、DVI和EVI，并且将这些指数同时与地上部生物量AGB建立了岭回归模型。共有180个样本用于拔节期模型的建立，其中108个样本用于建模。从图5-2的结果可以看出，这些植被指数与地上部生物量模型的决定系数为0.868，在玉米拔节期中表现出很好的模型效果。




图 5-2 拔节期监测模型

Figure 5-2 Joint phase monitoring model

### 5.2.2 玉米吐丝期地上部生物量建模分析

在感兴趣的地区，利用吐丝期采集的数据提取了多种植被指数，包括NDVI、RVI、OSAVI、DVI和EVI，并与地上部生物量同时建立了岭回归模型。其中，180个样本用于吐丝期模型的构建，其中108个样本用于建模。从图5-3的结果可以看出，在玉米拔节期，所建立的多种植被指数与地上部生物量模型的决定系数为0.892，表明模型效果较好。




图 5-3 吐丝期监测模型

Figure 5-3 Spitting phase monitoring model

### 5.2.3 玉米灌浆期地上部生物量建模分析

在感兴趣区域中，使用灌浆期采集的数据，提取各种植被指数与地上部生物量（AGB）建立岭回归模型。共有180个样本用于灌浆期模型的建立，其中108个样本用于建模，并且得到了如图5-4所示的结果。从图中可以看出，在玉米拔节期，多种植被指数与地上部生物量模型的决定系数达到了0.816，说明建立的模型效果较好。




图 5-4 灌浆期监测模型

Figure 5-4 Grouting period monitoring model

基于三个生育期的建模情况，从散点图的分布来看，要比偏最小二乘法 and 岭回归算法更加紧凑些。而且多种植被指数与地上部生物量都有良好的线性拟合关系，明显高于单一植被指数与地上部生物量的线性关系。BP神经网络结构中五个植被指数作为输入因子，在预测生物量中具有良好的提高精度的作用。虽然容易受到不同因素的影响，但是可以通过处理进行优化。另外，对比发现，灌浆期在多种植被指数与地上部生物量的决定系数为 0.816，低于其他时期的模型结果，说明灌浆期这个关键时期在BP神经网络模型中预测不是很好，反演效果不佳。

### 5.3 基于BP神经网络模型的模型检验

利用独立样本数据进行预测，将实测值和预测值进行比较，并通过 $R^2$ 和RMSE这两个评价指标来构建玉米地上部生物量的预测值与实测值的1:1关系图，以评价所建立模型的可信度。同时，通过预测每个观测阶段的模型，得到最佳的反演模型。

#### 5.3.1 玉米拔节期地上部生物量模型检验

在感兴趣区域内，使用拔节期的训练模型，对72个样本进行了预测。根据图5-5可以看出，使用拔节期的各植被指数NDVI、RVI、OSAVI、DVI、EVI与AGB建立BP神经网络模型的模型检验是比较准确的。实测值与预测值之间表现出良好的一致性，决定系数( $R^2$ )达到了0.831，这说明建立的模型效果较好，模型能够较为准确地预测地上部生物量。




图 5-5 拔节期模型检验

Figure 5-5 Model test at jointing stage

### 5.3.2 玉米吐丝期地上部生物量模型检验

在感兴趣区域内，使用吐丝期的训练模型，对72个样本进行了预测。根据图5-6可以看出，使用吐丝期的各植被指数NDVI、RVI、OSAVI、DVI、EVI与AGB建立BP神经网络模型的模型检验是比较准确的。实测值与预测值之间表现出良好的一致性，决定系数( $R^2$ )达到了0.874，这说明建立的模型效果较好，模型能够较为准确地预测地上部生物量。




图 5-6 吐丝期模型检验

Figure 5-6 Test of model in spinning stage

### 5.3.3 玉米灌浆期地上部生物量模型检验

在感兴趣区域内，使用灌浆期的训练模型，对72个样本进行了预测。根据图5-7可以看出，使用拔节期的各植被指数NDVI、RVI、OSAVI、DVI、EVI与AGB建立BP神经网络模型的模型检验是比较准确的。实测值与预测值之间表现出良好的一致性，决定系数( $R^2$ )达到了0.928，这说明建立的模型效果较好，模型能够较为准确地预测地上部生物量。




图 5-7 灌浆期模型检验

Figure 5-7 Model test at grout stage

从上面实测值-预测值模型的模型检验中可以看出，三个生育期的模型检验都达到了 0.831 以上，说明建模结果良好，可以作为玉米地上部生物量的反演模型。

#### 5.4 本章小结

本章基于前两章的基础，深入研究分析了利用 5 种不同的植被指数融合的方法反演监测地上部生物量。首先采用 BP 神经网络进行建模和验证，并与偏最小二乘法模型和岭回归模型进行对比。分析了不同方法处理下的玉米地上部生物量反演模型，其中拔节期的植被指数和 AGB 回归模型的  $R^2$  为 0.868，RMSE 为  $7.62\text{g/m}^2$ ；吐丝期的植被指数和 AGB 回归模型的  $R^2$  为 0.892，RMSE 为  $13.31\text{g/m}^2$ ；灌浆期的植被指数和 AGB 回归模型的  $R^2$  为 0.816，RMSE 为  $22.27\text{g/m}^2$ 。综合分析结果，BP 神经网络模型，成功实现了对玉米 AGB 的预测以及长势的监测。

## 第6章 各模型结果对比分析

### 6.1 各模型的模型检验对比

拔节期各个模型对感兴趣区域的地上部生物量模型检验中,选取其中的80个样本进行对比,模型检验如图6-1所示。由图可以看出实测的地上部生物量与预测得到的地上部生物量具有很强的相关性,各模型抽取出来的样本模型检验的决定系数 $R^2$ 为0.875,均方误差MSE为 $3.36\text{g}/\text{m}^2$ 。偏最小二乘算法、岭回归算法、BP神经网络构建的预测模型描述地上部生物量数据具有良好的精确度。




图 6-1 模型检验

Figure 6-1 Prediction results

吐丝期各个模型对感兴趣区域的地上部生物量模型检验中,选取其中的80个样本进行对比,模型检验如图6-2所示。由图可以明显的看出实测的地上部生物量与预测得到的地上部生物量具有很强的相关性,三种模型抽取出来的样本的决定系数 $R^2$ 为0.863,均方误差MSE为 $12.24\text{g}/\text{m}^2$ ,数据表现良好。




图 6-2 模型检验

Figure 6-2 Prediction results

灌浆期各个模型对感兴趣区域的地上部生物量估测结果中,选取其中的80个样

本进行对比，模型检验如图6-3所示。各模型抽取出来的样本精度较高，决定系数 $R^2$ 为0.913，均方误差MSE为36.4g/m<sup>2</sup>，灌浆期数据误差较小，预测精度较高。




图 6-3 模型检验

Figure 6-3 Prediction results

通过上述分析可以得出，偏最小二乘法模型、岭回归算法模型、BP神经网络模型中，在灌浆期的预测效果好些，决定系数达到了0.913。

6.2 各模型精度对比分析

6.2.1 建模结果精度分析

本文旨在比较偏最小二乘法模型、岭回归模型和BP神经网络构建的模型，以确定最佳模型来反演感兴趣区域的地上部生物量。采用 $R^2$ 、RMSE、NRMSE和PA这三个参数来评估模型的精度，并对结果进行对比分析。如表 6-1 所示。

表 6-1 各模型的精度对比分析

Table 6-1 Comparative analysis of accuracy of each model

模型	$R^2$	RMSE (g/m <sup>2</sup> )	NRMSE (%)	PA (%)
拔节期NDVI-AGB	0.756	4.04	20.20	73.2%
吐丝期EVI-AGB	0.883	9.91	22.02	82.5%
灌浆期RVI-AGB	0.894	16.37	19.74	83.6%
拔节期岭回归模型	0.906	7.34	26.70	91.1%
吐丝期岭回归模型	0.832	10.69	22.27	84.5%
灌浆期岭回归模型	0.834	19.91	25.06	86.9%
拔节期BP神经网络	0.868	7.62	24.60	89.5%
吐丝期BP神经网络	0.892	13.31	19.57	86.6%
灌浆期BP神经网络	0.816	22.27	12.10	85.5%



根据表6-1可以得知,经过对比多种模型后发现,在三个时期中,BP神经网络的精度高于其他的预测模型。在拔节期,BP神经网络的决定系数 $R^2$ 为0.868,均方根误差RMSE为 $7.62\text{g/m}^2$ ,归一化均方根误差NRMSE为24.60%,预测精度达到了89.5%。相较于偏最小二乘法模型的建模 $R^2$ 提高了0.112,较岭回归算法的建模 $R^2$ 降低了0.038。在吐丝期,决定系数 $R^2$ 为0.892,均方根误差RMSE为 $13.31\text{g/m}^2$ ,归一化均方根误差NRMSE为19.57%,预测精度达到了86.6%。相较于偏最小二乘法模型的建模 $R^2$ 提高了0.009,较岭回归算法的建模 $R^2$ 提高了0.06。在灌浆期,决定系数 $R^2$ 为0.816,均方根误差RMSE为 $22.27\text{g/m}^2$ ,归一化均方根误差NRMSE为12.10%,预测精度达到了85.5%。相较于偏最小二乘法模型的建模 $R^2$ 降低了0.078,较岭回归算法的建模 $R^2$ 降低了0.018。

但是,岭回归模型在拔节期的预测精度最高,决定系数 $R^2$ 为0.906,均方根误差RMSE为 $7.34\text{g/m}^2$ ,归一化均方根误差NRMSE为26.70%,预测精度达到了91.1%。相较于偏最小二乘法模型的建模 $R^2$ 提高了0.15,较BP神经网络的建模 $R^2$ 提高了0.038。主要因为岭回归模型在拔节期具有多种植被指数进行估测的优势。相比之下,偏最小二乘模型只是单一植被指数与地上部生物量的预测模型,其受其他因素的影响较大。而在大田实验中,会受到密度、光照、土壤等条件的影响。而在多种神经元结合的情况下,BP神经网络可以得到更高的精度。另外,由于支持BP神经网络模型是多种植被指数拟合后的结果,所以在一定程度上受其他因素的影响较小,从而得到的精度更高。

### 6.2.2 模型检验精度分析

在偏最小二乘法模型、岭回归模型和BP神经网络构建的不同模型中,模型检验存在差异。针对感兴趣区域下的地上部生物量反演模型,进行精度对比分析。通过 $R^2$ 、RMSE、NRMSE和PA三个参数,对不同模型进行比对,找出表现最佳的地上部生物量反演模型,见表6-2。

表 6-2 各模型的精度对比分析

Table 6-2 Comparative analysis of accuracy of each model

模型	$R^2$	RMSE ( $\text{g}/\text{m}^2$ )	NRMSE (%)	PA (%)
拔节期EVI-AGB	0.887	4.96	19.84	84.5%
吐丝期RVI-AGB	0.901	9.36	17.01	89.3%
灌浆期DVI-AGB	0.917	16.99	28.31	87.3%
拔节期岭回归模型	0.845	7.85	31.40	83.7%
吐丝期岭回归模型	0.890	12.03	14.73	84.6%
灌浆期岭回归模型	0.868	23.98	25.16	85.5%
拔节期BP神经网络	0.831	8.27	30.59	84.9%
吐丝期BP神经网络	0.874	12.42	24.84	91.4%
灌浆期BP神经网络	0.928	21.32	9.84	92.6%

由表 6-2 可知, 对比多个模型后发现BP神经网络精度在三个时期高于其他的预测模型, 拔节期决定系数 $R^2$ 为 0.831, 均方根误差RMSE为 $8.27\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE为30.59%, 预测精度达到了 84.9%。相较于偏最小二乘法模型的建模 $R^2$ 降低了0.056, 较岭回归算法的建模 $R^2$ 提高了0.014。吐丝期决定系数 $R^2$ 为 0.874, 均方根误差RMSE为 $12.42\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE为24.84%, 预测精度达到了91.4%。相较于偏最小二乘法模型的建模 $R^2$ 降低了0.027, 较岭回归算法的建模 $R^2$ 提高了0.016。灌浆期决定系数 $R^2$ 为0.928, 均方根误差RMSE为 $21.32\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE为9.84%, 预测精度达到了92.6%。相较于偏最小二乘法模型的建模 $R^2$ 提高了0.011, 较岭回归算法的建模 $R^2$ 提高了0.06。

但是在偏最小二乘法在吐丝期、灌浆期也有突出表现, 决定系数 $R^2$ 分别达到了0.901和0.917, 均方根误差RMSE分别为 $9.36\text{g}/\text{m}^2$ 和 $16.99\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE分别为17.01%和28.31%, 预测精度达到了89.3%和87.3%。主要因为偏最小二乘法在吐丝期、灌浆期具有优势, 单一植被指数进行估测, 而岭回归模型因为是受其他因素的影响较大, 加上本身是放弃无偏性, 以损失部分信息、降低精度来实现的, 所以在精度上有多降低。BP神经网络在多种植被指数融合的条件下, 对于建模精度和模型检验精度都较高, 可以作为玉米在拔节期、吐丝期、灌浆期的统一预测模型。

### 6.3 地上部生物量反演结果

通过之前得出的结论，在ENVI 5.3软件中把由BP神经网络模型中预测得到的三个生育期AGB进行反演，不同的颜色代表不同的地上部生物量数值大小。反演结果玉米地上部生物量空间分布图如图6-4所示：




图 6-4 玉米地上部生物量空间分布图

Figure 6-4 Spatial distribution of aboveground biomass in maize

由云南省德宏州芒市勐戛镇玉米试验地的地上部生物量反演结果分布情况可以看出，当玉米处在拔节期时，整体的地上部生物量值较小，主要集中分布在13.04g—28.22 g之间。吐丝期反演的地上部生物量最大值为69.34g，最小值为26.26g，主要分布与26.26g—69.34g之间。灌浆期反演的地上部生物量最大值为205.25g，最小值为155.7g，主要分布与155.7g—205.25g之间。玉米的每个生育阶段估算结果与实际采集的地上部生物量比较符合，变化不大，而且随着玉米的生长，地上部生物量渐渐升高，符合实际生长情况。

### 6.4 本章小结

本章是对所运用的模型进行总结，包括了各模型的模型检验对比和精度对比分析。模型检验对比中，拔节期，各模型抽取出来的样本模型检验的决定系数 $R^2$ 为0.875，均方误差MSE为3.36g/m<sup>2</sup>；吐丝期，各模型抽取出来的样本的决定系数 $R^2$ 为0.863，均方误差MSE为12.24g/m<sup>2</sup>；灌浆期，各模型抽取出来的样本决定系数 $R^2$ 为0.913，均方误差MSE为36.4g/m<sup>2</sup>。可以看出各模型对于地上部生物量的预测效果较好。建模结果精度对比中，拔节期的岭回归模型精度最高，达到了91.1%，模型检验精度对比中，灌浆期的三个经验模型中，要属BP神经网络模型精度最高，达到了92.6%。

## 第7章 总结与展望

### 7.1 总结

本文研究2022-2023年云南省楚雄州双柏县爱尼山乡和云南省德宏州芒市勐戛镇试验地的玉米,使用大疆精灵4五波段多光谱相机(P4M)采集遥感影像,并结合地面采集的玉米数据,基于5种常用植被指数对不同密度处理水平下的大田玉米进行地上部生物量的反演研究。研究结果表明:

(1) 本研究在采集遥感影像之前进行了三次试验,分别使用了15米、25米和35米的飞行高度,并对航向重叠度和旁向重叠度进行了调整,以确定最佳的飞行参数设置。最终确定的最佳飞行参数为:飞行高度为15米,航向重叠度为80%,旁向重叠度为70%,以获得最佳的遥感影像效果。这样可以减小遥感影像中的畸变,提高影像的质量和准确性。

(2) 利用偏最小二乘算法,建立了一种模型来分析不同物候期的地上部生物量和单一植被指数之间的关系。对各生育期的模型进行对比分析后,结果显示在不同阶段条件下,拔节期的NDVI-AGB相关性、吐丝期的EVI-AGB相关性和灌浆期的RVI-AGB相关性比其他四种植被指数相关性更高。其中,灌浆期的RVI-AGB相关性最高,决定系数 $R^2$ 为0.894,均方根误差RMSE为16.37g/m<sup>2</sup>,归一化均方根误差NRMSE为19.74%。在模型检验中,拔节期EVI-AGB相关性、吐丝期RVI-AGB相关性和灌浆期的DVI-AGB相关性比其他四种植被指数相关性更高。其中,灌浆期的DVI-AGB相关性最高,决定系数 $R^2$ 为0.917,均方根误差RMSE为16.99g/m<sup>2</sup>,归一化均方根误差NRMSE为28.31%。试验结果表明,偏最小二乘法模型在灌浆期可以较准确的预测玉米地上部生物量,同时比较五种植被指数中预测效果最好的是DVI和RVI。

(3) 利用岭回归算法,建立了地上部生物量与多种植被指数之间的模型,并考虑到不同的观测阶段。结果显示,在拔节期建模分析中,模型的決定系数 $R^2$ 为0.906,均方根误差RMSE为7.34g/m<sup>2</sup>,归一化均方根误差NRMSE为26.70%;在吐丝期,模型的決定系数 $R^2$ 为0.832,均方根误差RMSE为10.69g/m<sup>2</sup>,归一化均方根误差NRMSE为22.27%;在灌浆期,模型的決定系数 $R^2$ 为0.834,均方根误差RMSE为19.91g/m<sup>2</sup>,归一化均方根误差NRMSE为25.06%。利用剩余样本进行模型精度评价,各时期模型预测的決定系数分别为0.845、0.890、0.868。试验结果表明,岭回归模型在吐丝期可以较准确的预

测玉米地上部生物量。

(4) 利用BP神经网络, 将EVI、OSAVI、DVI、NDVI和RVI五种植被指标融合作为输入量, 以预测地上部生物量为输出量。经过训练和预测得出, BP神经网络模型具有较好的表现。在拔节期, 回归模型决定系数 $R^2$ 为0.868, 均方根误差RMSE为 $7.62\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE为24.60%; 在吐丝期, 回归模型决定系数 $R^2$ 为0.892, 均方根误差RMSE为 $13.31\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE为19.57%; 在灌浆期, 回归模型决定系数 $R^2$ 为0.816, 均方根误差RMSE为 $22.27\text{g}/\text{m}^2$ , 归一化均方根误差NRMSE为12.10%。在利用剩余样本进行模型评价时, 各时期模型预测的决定系数分别为0.831、0.874、0.928。此外, BP神经网络模型对地上部生物量的训练集预测准确率为90.31%, 召回率为86.47%。试验结果表明, BP神经网络在灌浆期可以较准确的预测玉米地上部生物量。

(5) 将得到的偏最小二乘法模型、岭回归模型和BP神经网络模型进行结果对比分析, 发现BP神经网络是最佳的反演模型。拔节期建模结果精度达到了89.5%, 吐丝期建模结果精度达到了86.6%, 灌浆期建模结果精度达到了85.5%。拔节期模型检验精度达到了84.9%, 吐丝期模型检验精度达到了91.4%, 灌浆期模型检验精度达到了92.6%, 较其他模型精度均有提高。因此最终选择BP神经网络模型对不同观测阶段的玉米遥感影像进行了AGB反演, 得到地上部生物量空间分布图。

## 7.2 展望

本文通过无人机多光谱遥感技术, 实现了对玉米地上部生物量的有效估测, 同时也能够获取即时可靠的长势信息。但是, 仍然存在不足之处, 希望以后可以改进, 如下几个方面:

(1) 本文在研究玉米地上部生物量预测过程中, 仅仅做了三个物候期的预测, 没有把玉米其它物候期覆盖, 后续研究可以将多个物候期加以研究, 并能否通过单一预测地上部生物量来预测其它时期的生物量。且本文应用在PLSR模型的是单一植被指数, 可以在以后的应用加入多种植被指数。

(2) 在获取玉米实测值的时候, 取样的时候应当尽量把根部以上的位置获取, 使数据更贴合实际。本研究实验的玉米品种不多, 在以后的研究中, 可以扩大不同玉米的覆盖。以便用于更多的作物预测地上部生物量, 帮助农户预测农作物长势, 提供意见。

## 参考文献

- [1] 李少昆, 王崇桃. 玉米高产潜力·途径[M]. 科学出版社, 2010.
- [2] 杨镇, 才卓, 景希强, 等. 东北玉米北京: 中国农业出版社, 2007.
- [3] 岳德荣. 中国玉米品质区划与产业布局: 中国农业出版社, 2004.
- [4] 赵久然, 王荣焕中国玉米生产发展历程、存在问题及对策中国农业科技导报, 2013, 15(3):1-6.
- [5] 曾智勇. 我国玉米生产现状分析及建议[J].粮油与饲料科技,2022(03):4-8.
- [6] 樊鸿叶, 李姚姚, 卢宪菊, 顾生浩, 郭新宇, 刘玉华. 基于无人机多光谱遥感的春玉米叶面积指数和地上部生物量估算模型比较研究[J].中国农业科技导报,2021,23(09):112-120.
- [7] 张善平. 种植密度和行距配置对高产夏玉米冠层特性的调控效应研究[D].山东农业大学,2014.
- [8] 张文龙, 李玉环, 赵洋. 基于ETM/SPOT5数据的玉米田地上部生物量遥感估算模型研究[C].Proceedings of 2011 AASRI Conference on Artificial Intelligence and Industry Application (AASRI-AIIA 2011 V3) .,2011:350-356.
- [9] 周敏姑, 邵国敏, 张立元, 姚小敏, 韩文霆. 无人机多光谱遥感反演冬小麦SPAD值[J].农业工程学报,2020,72(20):125-133.
- [10] 武婕. 玉米成熟期地上部生物量及其碳氮累积量的遥感估算[D].山东农业大学,2014.
- [11] 张辉, 杨张瑜, 柴茜. 无人机遥感技术在农业中的应用研究[J].南方农机,2023,54(02):56-58.
- [12] 刘杨, 孙乾, 黄珏, 冯海宽, 王娇娇, 杨贵军. 无人机多光谱影像的马铃薯地上部生物量估算[J].光谱学与光谱分析,2021,41(08):2549-2555.
- [13] 韩文霆, 彭星硕, 张立元, 牛亚晓. 基于多时相无人机遥感植被指数的夏玉米产量估算[J].农业机械学报,2020,51(01):148-155.
- [14] 米兆荣, 张耀生, 赵新全, 等. NDVI和EVI在高寒草地牧草鲜质量估算和植被动态监测中的比较[J]. 草业科学,2010,27(6):13-19.
- [15] 唐强, 蔡少辉, 周永桢, 高杰. 无人机在低空遥感中的应用[J]. 南方农机,2023,54(07):77-79+118.
- [16] 张芳毓, 谭永毅, 聂婧, 云俊文, 孙甲玲, 牛向丽. 无人机多光谱在农业中的应用[J].智慧农业导刊,2022,2(24):11-13.
- [17] 杜芳芳, 何晓平, 陈晓明, 常娜娜, 张文清. 无人机技术在农业监测中的应用及优劣势[J].现代农业科技,2020(13):172-174.
- [18] 胡晓. 基于无人机遥感的高潜水位煤矿区沉陷耕地信息提取方法[D].山东农业大学,2020.
- [19] 黄登红, 周忠发, 彭睿文, 朱孟, 尹林江, 张扬, 肖冬娜, 黎前霞, 胡灵炆, 黄有燕. 西南高原山区作物低空遥感挑战与主要研究进展[J].贵州师范大学学报(自然科学版), 2021,39(05):51-59.
- [20] 孟令宣. 无人机多源遥感影像配准方法及其在地面目标解译中的应用[D].电子科技大学,2022.

- [21] 张艳, 陈丕. 无人机多光谱遥感技术在农业统计中的运用[J].南方农机,2022,53(16):86-88.
- [22] 马仪, 黄组桂, 贾江栋, 罗林育, 王爽, 姚一飞. 基于无人机-卫星遥感升尺度的土壤水分监测模型研究[J/OL].农业机械学报:1-24[2023-04-11].
- [23] 陈成, 杨栋淏, 李亚强, 辛京达, 王建雄. 基于无人机遥感技术的玉米长势监测研究[J].湖北农业科学,2022,61(20):179-181+210.
- [24] 沈海军. 无人机的发展与应用[J]. 科学新闻,2023,25(01):42-45.
- [25] 刘春生. 农用植保无人机的研究现状及趋势[J].农机使用与维修,2022(07):176-178.
- [26] 台翔. 植被覆盖条件下的无人机多光谱遥感土壤含盐量监测模型[D].西北农林科技大学,2022.
- [27] 鲁恒, 李永树, 李何超, 等. 无人机影像数字处理及在地震灾区重建中的应用[J].西南交通大学学报, 2010, 45(4): 533-573.
- [28] 尹逊堂. 植保无人机在小麦病虫害防治中的技术应用[J].农业开发与装备,2021,No.237(09):26-27.
- [29] 赵庆展, 刘 伟, 尹小君, 等. 基于无人机多光谱影像特征的最佳波段组合研究[J]. 农业机械学报,2016, 47(3): 242-248.
- [30] 李 冰, 刘镭源, 刘素红, 等. 基于低空无人机遥感的冬小麦覆盖度变化监测[J]. 农业工程学报,2012, 28(13): 160-165.
- [31] 汪小钦, 王苗苗, 王绍强, 等. 基于可见光波段无人机遥感的植被信息提取[J]. 农业工程学报,2015, 31(5): 152-159.
- [32] 张正健, 李爱农, 边金虎, 等. 基于无人机影像可见光植被指数的若尔盖草地地上部生物量估算研究[J]. 遥感技术与应用, 2016, 31(1): 51-62.
- [33] 宋成阳. 无人机表型技术在冬小麦产量性状鉴定中的应用[D].新疆农业大学,2022.
- [34] 肖武, 陈佳乐, 笪宏志, 等. 基于无人机影像的采煤沉陷区玉米生物量反演分析[J].农业机械学报, 2018,49(08):169-180.
- [35] 于翔, 包琼. 无人机多光谱影像的马铃薯地上部生物量估算[J].南方农机,2023,54(04):96-99.
- [36] 程冀文, 王树森, 罗于洋等. 基于BP神经网络的沙柳地上部生物量预测模型[J].林业科学研究,2022,35(03):193-198.
- [37] 邓江, 谷海斌, 王泽, 盛建东, 马煜成, 信会男. 基于无人机遥感的棉花主要生育时期地上部生物量估算及验证[J].干旱地区农业研究,2019,37(05):55-61+69.
- [38] 邹楠, 杨文杰, 肖春华, 等. 种植密度对玉米冠层高光谱特征的响应研究[J].石河子大学学报(自然科学版),2017,35(6):687-692.
- [39] 庄东英, 李卫国, 武立权. 冬小麦生物量卫星遥感估测研究[J].干旱区资源与环境,2013,27(10):158-162.
- [40] Meiyan Shu,Mengyuan Shen,Qizhou Dong,Xiaohong Yang,Baoguo Li,Yuntao Ma. Estimating the maize above-ground biomass by constructing the tridimensional concept model based on UAV-based

- digital and multi-spectral images[J]. Field Crops Research,2022,282.
- [41] Lu Ning,Zhou Jie,Han Zixu,Li Dong.Improved estimation of aboveground biomass in wheat from RGB imagery and poing cloud data acquired with a low-cost unmanned aetial system.[J].Plant methods,2019,15.
- [42] Mengmeng D,Noboru N.Monitoring of Wheat Growth Status and Mlapping of Wheat Yield's within-Field Spatial Variations Using Color Images Acquired from UAV-camera System[J]. Remote Sensing,2017,9(3):289-.
- [43] Jiang Q,Fang S,Peng Y,et al.UAV-Based Biomass Estimnation for Rice-Combining Spectral, TIN-Based Structural and Meteorological Features[J].Remote Sensing,2019,11(7).
- [44] Rueda-Ayala V,Peña,José,Höglind,Mats,et al.Comparing UAV-Based Technologies and RGB-D Reconstruction Methods for Plant Height and Biomass Monitoring on Grass Ley[J]. Sensors,2019,19(3).
- [45] 李淑贞, 徐大伟, 范凯凯, 陈金强, 佟旭泽, 辛晓平, 王旭. 基于无人机与卫星遥感的草原地上部生物量反演研究[J].遥感技术与应用,2022,37(01):272-278.
- [46] 杨伟忠. 基于无人机机载RGB和多光谱图像的可食牧草生物量估算方法研究[D].南京农业大学,2020.
- [47] 陈成, 杨栋淏, 李亚强, 辛京达, 王建雄. 基于无人机遥感技术的玉米长势监测研究[J].湖北农业科学,2022,61(20):179-181+210.
- [48] 刘明, 冯锐, 纪瑞鹏, 武晋雯, 王宏博, 于文颖. 基于MODIS-NDVI的春玉米叶面积指数和地上部生物量估算[J].中国农学通报,2015,31(06):80-87.
- [49] 毕瑞, 甘淑, 袁希平, 李绕波, 高莎. 不同地形环境下无人机航线规划及三维建模分析[J].测绘通报,2022(04):83-89+129.
- [50] 何勇, 杜晓月, 郑力源, 朱姜蓬, 岑海燕, 许丽佳. 无人机飞行高度对植被覆盖度和植被指数估算结果的影响[J].农业工程学报,2022,38(24):63-72.
- [51] 聂松伟. 基于无人机多光谱遥感的冬小麦长势指标监测[D].新疆农业大学,2022.
- [52] 贺佳, 王来刚, 郭燕, 张彦, 杨秀忠, 刘婷, 张红利. 基于无人机多光谱遥感的玉米LAI估算研究[J].农业大数据学报,2021,3(04):20-28.
- [53] 牛志春, 倪绍祥. 青海湖环湖地区草地植被生物量遥感监测模型[J]. 地理学报, 2003(5): 695-702.
- [54] 谭昌伟, 黄义德, 黄文江, 王纪华, 赵春江, 刘良云. 夏玉米叶面积指数的高光谱遥感植被指数法研究[J], 安徽农业大学学报, 2004,31(4): 392-397
- [55] 蒙继华, 吴炳方, 李强子. 全国农作物叶面积指数遥感估算方法[J]. 农业工程学报, 2007(02): 160-167.
- [56] 傅银贞, 汪小钦, 江洪. 马尾松LAI与植被指数的相关性研究[J]. 国土资源遥感, 2010(03): 41-46.



- [57] 田振坤,傅莺莺,刘素红,等. 基于无人机低空遥感的农作物快速分类方法[J]. 农业工程学报,2013, 29(7): 109-116.
- [58] Yulin Zhan,Shakir Muhammad,Pengyu Hao,Zheng Niu. The effect of EVI time series density on crop classification accuracy[J]. Optik,2018,157.
- [59] RONDEAUX G,STEVEN M,BARET F.Optimization of soil-adjusted vegetation indices[J]. Remote Sensing of Environment,1996,55( 2):95—107.
- [60] 张艳楠,牛建明,张庆,等. 植被指数在典型草原生物量遥感估测应用中的问题探讨[J]. 草业学报, 2012, 21(1): 229-238.
- [61] 刘姣娣,曹卫彬,李华,等. 基于植被指数的新疆棉花遥感估产模型研究[J]. 石河子大学学报(自然科学版), 2011, 29(2): 153-157.
- [62] 李茂刚,闫春华,杜瑶,张天龙,李华. 拉曼光谱结合偏最小二乘的甲醇汽油甲醇含量快速定量分析方法研究[J].光谱学与光谱分析,2021,41(07):2099-2104.
- [63] 吴远远. 老陈醋品质分析方法与实时检测装置研究[D].中北大学,2017.
- [64] 彭小婷,高文秀,王俊杰. 基于包络线去除和偏最小二乘的土壤参数光谱反演[J].武汉大学学报(信息科学版),2014,39(07):862-866.
- [65] 张智韬,王海峰,KARNIELI Arnon,陈俊英,韩文霆. 基于岭回归的土壤含水率高光谱反演研究[J].农业机械学报,2018,49(05):240-248.
- [66] 卢柳叶,张青峰,李光录. 基于BP神经网络的遥感影像分类研究[J].测绘科学,2012,37(06):140-143
- [67] 程冀文,王树森,罗于洋,张岑. 基于BP神经网络的沙柳地上部生物量预测模型[J].林业科学研究,2022,35(03):193-198.
- [68] 刘俊,孟庆岩,葛小三,刘顺喜,陈旭,孙云晓. 基于BP神经网络的夏玉米多生育期叶面积指数反演研究[J].遥感技术与应用,2020,35(01):174-184.
- [69] 程志强,蒙继华,纪甫江,汪洋,方慧婷,于丽红. 基于WOFOST模型与UAV数据的玉米生长后期地上部生物量估算[J].遥感学报,2020,24(11):1403-1418.
- [70] 王改堂,李平,苏成利. 岭参数优化的ELM岭回归学习算法[J]. 信息与控制,2011,40(04):497-500+506.
- [71] 高红. BP神经网络学习率的优化方法[J].长春师范学院学报(自然科学版),2010,29(04):29-31.
- [72] Qinghua GUO,Shichao JIN,Min LI.Application of deep learning in ecological resource research:Theories,methods,and challenges[J].Science China(Earth Sciences),2020,63(10):1457-1474.